





Fie  $\Omega$  mulțimea evenimentelor elementare (rezultatelor posibile) ale unui experiment aleator.

Definiție

$\mathcal{B} \subset \mathcal{P}(\Omega)$  este o  $\sigma$  – algebră dacă

- 1.  $\emptyset, \Omega \in \mathcal{B}$
- 2. Dacă  $A \in \mathcal{B}$  atunci  $A^C \in \mathcal{B}$
- 3. Dacă  $(A_n)_{n \in \mathbb{N}^+}, A_n \in \mathcal{B}$  atunci  $\bigcup_{n=1}^{\infty} A_n \in \mathcal{B}$

Perechea  $(\Omega, \mathcal{B})$  se numește *câmp de evenimente*.

Definiție

Se numește *probabilitate* pe  $\mathcal{B}$  o funcție nenegativă  $P : \mathcal{B} \rightarrow [0, 1]$  cu proprietățile:

- 1.  $P(\Omega) = 1$
- 2. Dacă  $A, B \in \mathcal{B}$  și  $A \cap B = \emptyset$  atunci  $P(A \cup B) = P(A) + P(B)$ .

Definiție

Triplețul  $(\Omega, \mathcal{B}, P)$  se numește *câmp de probabilitate*.

Proprietăți ale funcției de probabilitate

- 1.  $P(A^C) = 1 - P(A)$ , deoarece  $A \cup A^C = \Omega, A \cap A^C = \emptyset$ .
- 2.  $P(\emptyset) = P(\Omega^C) = 1 - P(\Omega) = 0$ .
- 3.  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ , dacă  $A \cap B \neq \emptyset$ .

Proprietatea 3. rezultă din relațiile (2) și (3).

$$\begin{aligned} A &= A \cap (B \cup B^C) = (A \cap B) \cup (A \cap B^C) \text{ cu } A \cap B \cap B^C = \emptyset \\ B &= B \cap (A \cup A^C) = (B \cap A) \cup (B \cap A^C) \text{ cu } B \cap A \cap A^C = \emptyset \\ A \cup B &= (A \cap B) \cup (A \cap B^C) \cup (B \cap A^C). \end{aligned} \tag{2}$$

Aplicăm axioma 2. din definiția probabilității și obținem

$$\begin{aligned} P(A) &= P(A \cap B) + P(A \cap B^C) \\ P(B) &= P(A \cap B) + P(B \cap A^C) \\ P(A \cup B) &= P(A \cap B) + P(A \cap B^C) + P(B \cap A^C). \end{aligned} \tag{3}$$

Exerciții

► Problema controlului alimentelor

Se știe că într-o cutie sunt 550 de mere. Se verifică aleator 25 dintre ele dacă sunt stricate. Dacă 2% dintre merele din cutie sunt stricate, care este probabilitatea ca printre cele 25 testate să găsim 2 mere stricate?

► Problema zilei de naștere

Care este probabilitatea ca cel puțin 2 persoane dintr-un grup de  $n$  indivizi să aibă aceeași zi de naștere?

Evenimente independente. Probabilitate condiționată

Exemplu 1: (1)

Definiție

Spunem că evenimentele  $A$  și  $B$  din  $\mathcal{B}$  sunt *independente* dacă nu se influențează, adică realizarea evenimentului  $A$  nu depinde de realizarea lui  $B$  și reciproc.

Definiție

Se numește *probabilitate condiționată a evenimentului  $A$  de către evenimentul  $B$*  și se notează  $P(A|B)$  sau  $P_{B|A}$  probabilitatea de realizare a evenimentului  $A$  calculată în condiția că evenimentul  $B$  s-a realizat ( $P(B) > 0$ ) și se definește ca:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \tag{4}$$

Exemplu 1: (2)

► Obținem următoarele probabilități:

$$P(\omega) = \frac{1}{700}, \forall \text{ evenimentul elementar } \omega \in \Omega$$

$$P(S) = \frac{562}{700} \approx 0,8$$

$$P(E) = \frac{138}{700} \approx 0,2$$

► Notăm cu

$\Omega_1$  = pacienții care au pietre mici

$\Omega_2$  = pacienții care au pietre mari

► Rezultă  $P(\Omega_1) = \frac{357}{700} = 0,51$  și  $P(\Omega_2) = \frac{343}{700} = 0,49$ . Astfel

$$P(S|\Omega_1) = \frac{P(S \cap \Omega_1)}{P(\Omega_1)} = \frac{315}{700} \cdot \frac{1}{0,51} = 0,88$$

Analog, se arată că  $P(S|\Omega_2) = 0,72$ .

Un tratament s-a aplicat la 700 de pacienți care sufereau de piatră la rinichi. S-a constatat că doar 562 s-au vindecat. De asemenea, se știe că 357 au pietre mici și 315 dintre aceștia s-au vindecat, iar 343 au pietre mari și 247 s-au vindecat. Să se calculeze probabilitatea ca un pacient să se vindece știind că acesta are piatră mică. Dar, dacă are piatră mare?

Soluție:

► Fie

$\Omega = \{1, 2, \dots, 700\}$  mulțimea tuturor pacienților,

$S = \{1, 2, \dots, 562\}$  mulțimea pacienților vindecați și

$E = \{563, \dots, 700\}$  mulțimea pacienților nevindecați.

Formula lui Bayes (1)

Fie  $(A_i)_{i=1,k}$  o partiție a mulțimii  $\Omega$ , ceea ce înseamnă că

$$A_i \cap A_j = \emptyset, \forall i, j \in \overline{1, k}, i \neq j, P(A_j) > 0, \forall j = \overline{1, k} \text{ și } \bigcup_{j=1}^k A_j = \Omega. \tag{5}$$

Fie  $X \in \mathcal{B}$  un eveniment oarecare. Atunci

$$\begin{aligned} P(X) &= P(X \cap \Omega) = P\left(\bigcup_{j=1}^k X \cap A_j\right) = \sum_{j=1}^k P(X \cap A_j) \\ &= \sum_{j=1}^k P(A_j) \cdot P(X|A_j) \end{aligned} \tag{6}$$

Obținem relația

$$P(X) = \sum_{j=1}^k P(A_j) \cdot P(X|A_j) \tag{7}$$

## Formula lui Bayes (2)

Atunci *probabilitatea condiționată a evenimentului  $A_j$  de către evenimentul  $X$*  se poate calcula cu formula

$$P(A_j|X) = \frac{P(A_j) \cdot P(X|A_j)}{\sum_{j=1}^k P(A_j) \cdot P(X|A_j)}. \tag{8}$$

Relația obținută în ecuația (8) se numește *formula lui Bayes*.

## Variabilă aleatoare

Fie  $(\Omega, \mathcal{B}, P)$  un câmp de probabilitate.

### Definiție

Numim *variabilă aleatoare (v.a.)* o funcție  $X : \Omega \rightarrow \mathbb{R}$  cu proprietatea că pentru fiecare  $x \in \mathbb{R}$  evenimentul

$$X^{-1}(x) = \{\omega \in \Omega | X(\omega) \leq x\} \text{ aparține mulțimii } \mathcal{B}. \tag{9}$$

### Exemplu

Pentru  $A \in \mathcal{B}$ , funcția indicator  $I_A$  definită prin

$$I_A(\omega) = \begin{cases} 1, & \omega \in A \\ 0, & \omega \notin A \end{cases} \tag{10}$$

este o variabilă aleatoare.

## Funcție de repartiție. Proprietăți ale funcției de repartiție

Fie evenimentul  $A = \{\omega \in \Omega | X(\omega) \leq x\} \stackrel{not}{=} \{X \leq x\} \in \mathcal{B}$ .

### Definiție

Funcția  $F_X : \mathbb{R} \rightarrow [0, 1]$  definită prin

$$F_X(x) = P(\{X \leq x\}) \stackrel{not}{=} P(X \leq x) \tag{11}$$

se numește *funcția de repartiție* a variabilei aleatoare  $X$ .

### Proprietăți ale funcției de repartiție

- $F_X(x) \in [0, 1], \quad \lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow \infty} F_X(x) = 1.$
- $F_X(x+h) \geq F_X(x)$ , pentru  $h > 0$ , deoarece  
$$F_X(x+h) = P(\{\omega \in \Omega | x < X(\omega) \leq x+h\}) + F_X(x).$$
- $P(\{\omega \in \Omega | a < X(\omega) \leq b\}) = F_X(b) - F_X(a)$ , pentru  $a < b$ .

## Variabilă aleatoare discretă

- Spunem că  $X$  este o *variabilă aleatoare discretă* dacă valorile luate de variabila aleatoare  $X$  sunt în număr finit sau numărabil.
- O v.a. discretă este definită prin tabloul:

$$X : \begin{pmatrix} x_1 & x_2 & \dots & x_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix} \tag{12}$$

unde  $x_1, x_2, \dots, x_n, \dots$  reprezintă valorile distincte pe care le poate lua v.a.  $X$ , iar  $p_n = P(\{\omega \in \Omega | X(\omega) = x_n\})$ ,  $n = 1, 2, \dots$

- Tabloul din ecuația (12) se numește *repartiția variabilei aleatoare discrete  $X$* .

1.  $p_1 + p_2 + \dots + p_n + \dots = 1$ , deoarece

$$p_1 + p_2 + \dots + p_n + \dots = P(\{\omega \in \Omega | X(\omega) = x_1\}) + P(\{\omega \in \Omega | X(\omega) = x_2\}) + \dots + P(\{\omega \in \Omega | X(\omega) = x_n\}) + \dots = P(\Omega) = 1$$

deoarece evenimentele

$A_i = \{\omega \in \Omega | X(\omega) = x_i\}$  și  $A_j = \{\omega \in \Omega | X(\omega) = x_j\}$  cu  $i \neq j$  sunt disjuncte (adică,  $A_i \cap A_j = \emptyset$ ; altfel avem evenimentul  $e \in A_i \cap A_j$ , de unde rezultă  $X(e) = x_i = x_j$ , ceea ce este imposibil pentru  $i \neq j$ ) și  $\bigcup_i A_i = \Omega$

2. O variabilă aleatoare discretă realizează o partiție a spațiului de selecție.

Definiție

Dacă  $X$  și  $Y$  sunt definite pe același câmp de probabilitate  $(\Omega, \mathcal{B}, P)$  atunci:

$$\begin{aligned} (X + Y)(\omega) &= X(\omega) + Y(\omega) \\ (aX)(\omega) &= aX(\omega), \text{ pentru } a \in \mathbb{R} \\ (XY)(\omega) &= X(\omega)Y(\omega) \\ \frac{X}{Y}(\omega) &= \frac{X(\omega)}{Y(\omega)}, \text{ dacă } Y(\omega) \neq 0 \text{ pentru orice } \omega \in \Omega \end{aligned}$$

Operații cu variabile aleatoare discrete (2)

Dacă

$$X : \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}, Y : \begin{pmatrix} y_1 & y_2 & \dots & y_m \\ q_1 & q_2 & \dots & q_m \end{pmatrix}$$

atunci

$$X + Y : \begin{pmatrix} x_1 + y_1 & x_1 + y_2 & \dots & x_i + y_j & \dots & x_n + y_m \\ p_{11} & p_{12} & \dots & p_{ij} & \dots & p_{nm} \end{pmatrix}$$

unde  $p_{ij} = P(\{\omega \in \Omega | X(\omega) = x_i\} \cap \{\omega \in \Omega | Y(\omega) = y_j\})$ .

$$aX : \begin{pmatrix} ax_1 & ax_2 & \dots & ax_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}$$

$$X \cdot Y : \begin{pmatrix} x_1y_1 & x_1y_2 & \dots & x_iy_j & \dots & x_ny_m \\ p_{11} & p_{12} & \dots & p_{ij} & \dots & p_{nm} \end{pmatrix}$$

și

$$X/Y : \begin{pmatrix} x_1/y_1 & x_1/y_2 & \dots & x_i/y_j & \dots & x_n/y_m \\ p_{11} & p_{12} & \dots & p_{ij} & \dots & p_{nm} \end{pmatrix}$$

Caracteristici ale v.a. discrete – definiții (1)

- Fie  $(\Omega, \mathcal{B}, P)$  spațiul de probabilitate pe care este definită variabila aleatoare discretă  $X$ .
- Dacă  $X$  este o variabilă aleatoare,  $X : \Omega \rightarrow \mathbb{R}$  atunci numim *valoare medie* a variabilei  $X$ ,

$$E[X] = \sum_{i=1}^{\infty} x_i p_i \tag{13}$$

pentru cazul în care  $X$  ia un număr numărabil de valori și seria este convergentă.

- Dacă  $X$  ia un număr finit de valori, valoarea medie se definește printr-o sumă finită.

## Caracteristici ale v.a. discrete – definiții (2)

- *Momentul centrat de ordin  $r$*  al v.a.  $X$  este numărul

$$\mu_r(X) = E[(X - E[X])^r] \quad (14)$$

- ▶ Pentru  $r = 2$

$$\mu_2(X) = E[(X - E[X])^2] \stackrel{not}{=} D(X) \quad (15)$$

se numește *dispersia* variabilei X.

- Dispersia  $D(X)$  dă o măsură a împrăstierii valorilor variabilei  $X$  în jurul valorii ei medii.

## Proprietăți ale mediei unei v.a. discrete (1)

1.  $E[aX + b] = aE[X] + b, a, b \in \mathbb{R}$

2.  $E[X + Y] = E[X] + E[Y]$

### Demonstratie

$$\begin{aligned} E[X + Y] &= \sum_{i=1}^n \sum_{j=1}^m (x_i + y_j) p_{ij} = \sum_{i=1}^n x_i \sum_{j=1}^m p_{ij} + \sum_{j=1}^m y_j \sum_{i=1}^n p_{ij} \\ &= \sum_{i=1}^n x_i P(X = x_i) + \sum_{j=1}^m y_j P(Y = y_j), \end{aligned}$$

deoarece

$$\sum_{j=1}^m p_{ij} = P((X = x_i) \cap \Omega) = P(X = x_i)$$

$$\sum_{i=1}^n p_{ij} = P(\Omega \cap (Y = y_j)) = P(Y = y_j)$$

## Proprietăți ale mediei unei v.a. discrete (2)

3. Dacă  $X$  și  $Y$  sunt v.a. independente atunci

$$E[X \cdot Y] = E[X] \cdot E[Y]$$

## Demonstratie

Avem  $E[X \cdot Y] = \sum_{i=1}^n \sum_{j=1}^m x_i y_j p_{ij}$ . Cum  $X$  și  $Y$  sunt independente

$$p_{jj} = P(X = x_j) \cdot P(Y = y_j).$$

Astfel,

$$E[X \cdot Y] = \sum_{i=1}^n x_i P(X = x_i) \cdot \sum_{j=1}^m y_j P(Y = y_j).$$

## Variabilă aleatoare continuă

### Definitie

Spunem că  $X : \Omega \rightarrow \mathbb{R}$  este *v.a. continuă* dacă

$$P(\{\omega \in \Omega | X(\omega) = x\}) = 0, \quad (16)$$

pentru orice  $x \in \mathbb{R}$ .

**Observatii:**

- ▶ Deși probabilitatea evenimentului din definiție este zero nu înseamnă că evenimentul nu se poate realiza.
- ▶ Dacă  $X$  este o variabilă aleatoare continuă atunci funcția sa de repartiție este continuă.







## Populație țintă

- ▶ **Populația țintă** este definită ca fiind întreaga colecție de obiecte sau indivizi despre care vrem să obținem anumite informații.
- ▶ Populația țintă trebuie **bine definită** indicând
  - ▶ ce constituie **membrii** acesteia (de ex, populația unei zone geografice, o anumită firmă care construiește componente hardware, etc.)
  - ▶ **caracteristicile** populației (de ex, starea de sănătate, numărul de defecțiuni, etc.).
- ▶ În majoritatea cazurilor este imposibil sau nerealist să observăm întreaga populație; cercetătorii măsoară numai o parte a populației țintă, denumită **eșantion**.
- ▶ Pentru a face inferențe privind întreaga populație este important ca **mulțimea eșantion** să fie **reprezentativă** relativ la întreaga populație.



### Selectie. Repartiția selecției

### Definitie

O **selecție** este o mulțime de v.a.  $X_1, X_2, \dots, X_n$  având aceeași densitate de repartiție  $f(x, \theta)$ .

- Deoarece selecția este o mulțime de variabile aleatoare asociate unui model probabilist, selecția trebuie să aibă o repartiție, pe care o vom numi *repartiția selecției*.

### Definitie

*Repartiția selecției*  $X_1, X_2, \dots, X_n$  este definită ca fiind repartiția vectorului  $X = (X_1, X_2, \dots, X_n)$ , notată prin  $f(x_1, x_2, \dots, x_n; \theta)$ .

- Cea mai folosită formă de selecție este selecția aleatoare și este bazată pe ideea experimentului aleator.



## Model probabilist

- Fie  $X$  o v.a. cu densitatea  $f(x, \theta)$ ,  $x \in \mathbb{R}, \theta \in \mathbb{R}$ .

### Definitie

Mulțimea densităților de repartiție  $f(x, \theta), \theta \in \Theta \subset \mathbb{R}$ , ce depind de parametrul  $\theta$  se numește *model probabilist unidimensional*.

$$\{f(x, \theta) | x \in \mathbb{R}, \theta \in \Theta\}. \quad (1)$$

- Fie  $X = (X_1, X_2, \dots, X_n)$  un vector aleator cu densitatea de repartitie

$$f(x_1, x_2, \dots, x_n; \theta), (x_1, x_2, \dots, x_n) \in \mathbb{R}^n, \theta \in \mathbb{R}^k.$$

### Definitie

Mulțimea densităților de repartiție  $f(x_1, x_2, \dots, x_n; \theta)$  cu parametrul  $\theta \in \Theta \subset \mathbb{R}^k$  se numește *model probabilist multidimensional*.

$$\{f(x_1, x_2, \dots, x_n; \theta) | \theta \in \Theta\}. \quad (2)$$



## Selectie aleatoare

### Definitie

Spunem că  $X_1, X_2, \dots, X_n$  este o **selectie aleatoare** asupra v.a.  $X$  care are densitatea de repartiție  $f(x; \theta)$  dacă  $X_1, X_2, \dots, X_n$  sunt v.a. independente și identic repartizate ca  $X$ .

$X_1, X_2, \dots, X_n$  se numesc *variabile de selectie*.

- ▶ În cazul selecției aleatoare, densitatea de repartiție comună a variabilelor de selecție este

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

- ▶ O selecție aleatoare poate fi construită prin repetarea unui experiment aleator de  $n$  ori.
- ▶ Un *rezultat al selecției aleatoare* se notează prin  $(x_1, x_2, \dots, x_n)$  și mulțimea tuturor rezultatelor definesc *spațiul observațiilor*  $S \equiv \mathbb{R}^n$ .



# Model statistic. Statistică

## Definiție

Modelul probabilist

$$\{f(x; \theta), \theta \in \Theta\}$$

Împreună cu selecția  $X = (X_1, X_2, \dots, X_n)$  definesc *modelul statistic*.

## Definiție

*Statistica* este o funcție  $t_n : S \rightarrow \Theta \subset \mathbb{R}^k$  care nu conține niciun parametru necunoscut.

- ▶ Cele mai utilizate statistici sunt momentele de selecție.

# Momente de selecție

- ▶ *Momentul de selecție de ordinul r*

$$m'_r(x_1, x_2, \dots, x_n) = \frac{1}{n} \sum_{j=1}^n x_j^r \tag{3}$$

- ▶ *Momentul de selecție de ordin 1 – media de selecție*

$$m'_1(x_1, x_2, \dots, x_n) = \overline{X}_n = \frac{1}{n} \sum_{j=1}^n x_j \tag{4}$$

- ▶ *Momentul centrat de selecție de ordin r*

$$m_r(x_1, x_2, \dots, x_n) = \frac{1}{n} \sum_{j=1}^n (x_j - \overline{X}_n)^r. \tag{5}$$

- ▶ *Momentul centrat de selecție de ordin 2 – dispersia de selecție*

$$m_2(x_1, x_2, \dots, x_n) = \frac{1}{n} \sum_{j=1}^n (x_j - \overline{X}_n)^2. \tag{6}$$

# Convergență în probabilitate

## Definiție

Șirul de v.a.  $(X_n)_n$  *converge în probabilitate* la v.a.  $X$  dacă

$$\lim_{n \rightarrow \infty} P(\{\omega \in \Omega, |X_n(\omega) - X(\omega)| < \epsilon\}) = 1. \tag{7}$$

## Propoziție

Avem relația

$$\overline{X}_n = \frac{1}{n} \sum_{j=1}^n X_j \xrightarrow[n \rightarrow \infty]{P} E[X] = \mu$$

# Estimator. Estimație

## Definiție

Se numește *estimator*, variabila aleatoare

$$t_n(X) : \Omega \rightarrow \Theta, \tag{8}$$

unde  $X = (X_1, X_2, \dots, X_n)$ ,  $\Omega$  este spațiul de selecție;  $t_n(x), x \in S$ ,  $S$  spațiul observațiilor, se numește *estimație*.

## Definiție

Un estimator  $t_n = t_n(X)$  se numește *consistent* pentru  $\theta$  dacă

$$\lim_{n \rightarrow \infty} P(|t_n - \theta| < \epsilon) = 1 \tag{9}$$

și notăm  $t_n \xrightarrow{P} \theta$ .

- ▶ Consistența unui estimator reprezintă o proprietate asimptotică a estimatorului.
- ▶ Un estimator bun pentru parametrul  $\theta$  trebuie să aibă o repartiție cu o valoare centrală în vecinătatea lui  $\theta$ .
- ▶ Definiția următoare cere ca estimatorul să aibă o valoare centrală în vecinătatea lui  $\theta$  nu numai pentru valori mari ale lui  $n$ , ci pentru orice  $n$ .

### Definitie

*Estimatorul*  $t_n$  se numește *nedeplasat* pentru  $\theta$  dacă

$$E[t_\theta] = \theta. \quad (10)$$



### Numere aleatoare uniform distribuite

Fie  $(\Omega, \mathcal{B}, P)$  un câmp de probabilitate.

### Definitie

(Variabilă aleatoare uniformă)

Spunem că *variabila aleatoare continuă*  $U : \Omega \rightarrow \mathbb{R}$  este *repartizată uniform* pe intervalul  $[a, b]$  și scriem  $U \sim \mathcal{U}(a, b)$  dacă *densitatea sa de repartiție* este de forma:

$$f(u) = \begin{cases} \frac{1}{b-a}, & \text{dacă } u \in [a, b] \\ 0, & \text{altfel} \end{cases} \quad (11)$$

**Funcția de repartiție**  $F(x)$  a v.a.  $U \sim \mathcal{U}(a, b)$  este definită prin

$$F(x) = \begin{cases} 0, & \text{dacă } x \leq a \\ \frac{x-a}{b-a}, & \text{dacă } x \in (a, b) \\ 1, & \text{dacă } x \geq b \end{cases} \quad (12)$$



- ▶ Majoritatea metodelor de generare a v.a. se bazează pe generarea unor numere aleatoare uniform distribuite pe intervalul  $(0,1)$ .
- ▶ Datorită calculatorului avem posibilitatea de a genera foarte ușor numere aleatoare uniforme.
- ▶ Totuși, trebuie cunoscut faptul că numerele generate de calculator sunt pseudo-aleatoare, deoarece acestea sunt generate cu un algoritm determinist.

### Observatii referitoare la repartitia uniformă si v.a. uniforme

- Probabilitatea ca v.a. uniformă  $U \sim \mathcal{U}(a, b)$  să cadă într-un interval  $[u_1, u_2]$ ,  $a \leq u_1 < u_2 \leq b$  este proporțională cu lungimea intervalului:

$$P(u_1 < U \leq u_2) = \frac{u_2 - u_1}{b - a}. \quad (13)$$

- Pentru a genera numere aleatoare uniform distribuite pe un interval  $[a,b]$ , și scriem  $X \sim \mathcal{U}(a, b)$ , pornind de la numere generate uniform pe intervalul  $[0,1]$  se poate folosi transformarea

$$X = (b - a) \cdot U + a, \quad (14)$$

unde  $U \sim \mathcal{U}(0, 1)$ .

## Generarea numerelor uniforme în Matlab (1)

- ▶ În Matlab există funcția **rand** pentru generarea variabilelor aleatoare uniforme.
- ▶ **rand(*n*)**, unde *n* este un număr natural, returnează o matrice de dimensiune  $n \times n$  având ca elemente numere aleatoare uniform distribuite între 0 și 1.
- ▶ **rand(*m*, *n*)**, unde *m*, *n* sunt numere naturale, returnează o matrice de dimensiune  $m \times n$  având ca elemente numere aleatoare uniform distribuite între 0 și 1.

◀ ▶ 🔍 ↺ ↻ ⌂

## Generarea numerelor uniforme în Matlab (4)

Exemplu care ilustrează utilizarea funcției **rand**.

```
% Generam un vector de numere aleatoare pe intervalul (0,1).
x = rand(1,1000);
% Histograma eșantionului generat în x.
[N, C] = hist(x,15);
% x: mulțimea eșantion
% 15 reprezintă numărul de dreptunghiuri ale histogramei
% N: vector conținând numărul de elemente din fiecare dintre dreptunghiuri.
% C: vector conținând centrele dreptunghiurilor
% Folosirea funcției bar pentru reprezentarea grafică a histogramei.
bar(C,N,1,'w')
title('Histograma asociata unei variabile aleatoare uniforme')
xlabel('X')
ylabel('Frecventa absoluta')
```

Histograma rezultată este prezentată în Figura 1.

◀ ▶ 🔍 ↺ ↻ ⌂

## Generarea numerelor uniforme în Matlab (2)

- ▶ O secvență de numere aleatoare generată în Matlab depinde de "sămânța" sau starea generatorului. Starea este resetată la valoarea implicită în momentul pornirii Matlab-ului, astfel aceeași secvență de variabile aleatoare este generată la o nouă pornire a Matlab-ului. Acesta poate fi un avantaj în situațiile în care analistul are nevoie să reproducă rezultatele unei simulări pentru a verifica anumite concluzii.
- ▶ **rng(SD)** setează sămânța generatorului pe baza întregului nenegativ *SD*
- ▶ **rng('shuffle')** setează sămânța generatorului pe baza momentului curent de timp
- ▶ **rng('default')** resetează setările generatorului la valorile inițiale, și anume, se folosește generatorul Mersenne Twister cu sămânța 0.

◀ ▶ 🔍 ↺ ↻ ⌂

## Generarea numerelor uniforme în Matlab (5)




Figura 1 – Histograma asociată unui eșantion de numere aleatoare uniform distribuite

◀ ▶ 🔍 ↺ ↻ ⌂





Funcții de o variabilă aleatoare (3): Exemplu 2

Structura generală a unui algoritm de generare/simulare a unei variabile aleatoare

Propoziție

Dacă  $X \sim U(0, 1)$  atunci variabila aleatoare

$$Y = \left(-\frac{1}{a} \ln(1 - X)\right)^{1/b}$$

cu  $a, b > 0$  are densitatea de probabilitate

$$f(y) = aby^{b-1}e^{-ay^b}, \quad 0 < y < \infty. \tag{4}$$

Definiție

O variabilă aleatoare cu densitatea de probabilitate (0.4) se numește Weibull cu parametrii  $a$  și  $b$  și este notată  $W(a, b)$ .

Intrare	$F(x)$ : funcția de repartiție a variabilei $X$ pe care ne propunem să o simulăm
Pas 1	Se generează valorile de selecție $u_1, u_2, \dots, u_n$ asupra v. a. $U_1, U_2, \dots, U_n$ uniforme pe $[0,1]$
Pas 2	Se definește $X = \phi(U_1, U_2, \dots, U_n)$ a.î. $F(x) = P(X \leq x), \forall x$
Pas 3	Se obține valoarea de selecție dorită $x = \phi(u_1, u_2, \dots, u_n)$
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$

Numere aleatoare

Numere aleatoare uniform distribuite

Fie  $(\Omega, \mathcal{B}, P)$  un câmp de probabilitate.

Definiție

(Variabilă aleatoare uniformă)

Spunem că *variabila aleatoare continuă*  $U : \Omega \rightarrow \mathbb{R}$  este *repartizată uniform* pe intervalul  $[a, b]$  și scriem  $U \sim \mathcal{U}(a, b)$  dacă *densitatea sa de repartiție* este de forma:

$$f_U(x) = \begin{cases} \frac{1}{b-a}, & \text{dacă } x \in [a, b] \\ 0, & \text{altfel} \end{cases} \tag{5}$$

*Funcția de repartiție*  $F_U(x)$  a v.a.  $U \sim \mathcal{U}(a, b)$  este definită prin

$$F_U(x) = \begin{cases} 0, & \text{dacă } x \leq a \\ \frac{x-a}{b-a}, & \text{dacă } x \in (a, b) \\ 1, & \text{dacă } x \geq b \end{cases} \tag{6}$$

- ▶ Majoritatea metodelor de generare a v.a. se bazează pe generarea unor numere aleatoare uniform distribuite pe intervalul  $(0,1)$ .
- ▶ Datorită calculatorului avem posibilitatea de a genera foarte ușor numere aleatoare uniforme.
- ▶ Totuși, trebuie cunoscut faptul că numerele generate de calculator sunt pseudo-aleatoare, deoarece acestea sunt generate cu un algoritm determinist.



- Probabilitatea ca v.a. uniformă  $U \sim \mathcal{U}(a, b)$  să cadă într-un interval  $[u_1, u_2]$ ,  $a \leq u_1 < u_2 \leq b$  este proporțională cu lungimea intervalului:

$$P(u_1 < U \leq u_2) = \frac{u_2 - u_1}{b - a}. \quad (7)$$

- Pentru a genera numere aleatoare uniform distribuite pe un interval  $[a, b]$ , și scriem  $X \sim \mathcal{U}(a, b)$ , pornind de la numere generate uniform pe intervalul  $[0, 1]$  se poate folosi transformarea

$$X = (b - a) \cdot U + a, \quad (8)$$

unde  $U \sim \mathcal{U}(0, 1)$ .

- În Matlab există funcția **rand** pentru generarea variabilelor aleatoare uniforme.

- **rand(*n*)**, unde *n* este un număr natural, returnează o matrice de dimensiune  $n \times n$  având ca elemente numere aleatoare uniform distribuite între 0 și 1.

- **rand(*m*, *n*)**, unde *m*, *n* sunt numere naturale, returnează o matrice de dimensiune  $m \times n$  având ca elemente numere aleatoare uniform distribuite între 0 și 1.

## Generarea numerelor uniforme în Matlab (2)

- O secvență de numere aleatoare generată în Matlab depinde de "sămânța" sau starea generatorului. Starea este resetată la valoarea implicită în momentul pornirii Matlab-ului, astfel aceeași secvență de variabile aleatoare este generată la o nouă pornire a Matlab-ului. Acesta poate fi un avantaj în situațiile în care analistul are nevoie să reproducă rezultatele unei simulări pentru a verifica anumite concluzii.
- **rng(SD)** setează sămânța generatorului pe baza întregului nenegativ *SD*
- **rng('shuffle')** setează sămânța generatorului pe baza momentului curent de timp
- **rng('default')** resetează setările generatorului la valorile inițiale, și anume, se folosește generatorul Mersenne Twister cu sămânța 0.

## Generarea numerelor uniforme în Matlab (3)

Exemplu care ilustrează utilizarea funcției **rand**.

```
% Generam un vector de numere aleatoare pe intervalul (0,1).
x = rand(1,1000);
% Histograma eșantionului generat în x.
[N,X] = hist(x,15);
% x: mulțimea eșantion
% 15 reprezintă numărul de dreptunghiuri ale histogramei
% N: vector conținând numărul de elemente din fiecare dintre dreptunghiuri.
% X: vector conținând centrele dreptunghiurilor
% Folosirea funcției bar pentru reprezentarea grafică a histogramei.
bar(X,N,1,'w')
title('Histograma asociata unei variabile aleatoare uniforme')
xlabel('X')
ylabel('Frecventa absoluta')
```

Histograma rezultată este prezentată în Figura 1.

## Generarea numerelor uniforme în Matlab (4)




Figura : 1 – Histograma asociată unui eșantion de numere aleatoare uniform distribuite

## Metoda inversă (2): Descrierea metodei

- ▶ este introdusă ca o consecință directă a teoremei lui Hincin
- ▶ se aplică în cazul în care funcția de repartiție se poate inversa ușor
- ▶ dacă am putea produce valorile de selecție  $u_1, u_2, \dots, u_n$  asupra v.a.  $U \sim \mathcal{U}(0, 1)$  și am cunoaște funcția de repartiție  $F$  a variabilei  $X$  atunci am putea produce valorile de selecție  $x_1, x_2, \dots, x_n$  asupra lui  $X$  cu formula  $x_i = F^{-1}(u_i), 1 \leq i \leq n$

## Metoda inversă (1): Teorema lui Hincin

### Propoziție

Fie  $X$  o variabilă aleatoare (v.a.) cu funcția de repartiție  $F(x)$  inversabilă și de tip continuu. Atunci variabila aleatoare  $Y = F(X)$  este repartizată uniform pe  $[0, 1]$ .

### Teoremă (Teorema lui Hincin)

Fie  $U \sim \mathcal{U}(0, 1)$  și  $F(x)$  o funcție de repartiție inversabilă, de tip continuu. Atunci variabila aleatoare

$$X = F^{-1}(U) \tag{9}$$

este o variabilă aleatoare continuă cu funcția de repartiție  $F(x)$ .

Demonstrație: Funcția de repartiție a v.a.  $X$  este

$$P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x))$$

deoarece  $F$  este monoton crescătoare.

Cum  $U \sim \mathcal{U}(0, 1)$  rezultă  $F_U(u) = u$  pentru  $u \in [0, 1]$ . Obținem astfel  $P(X \leq x) = F(x)$ .

## Metoda inversă (3): Algoritm pentru simularea unor variabile aleatoare continue

Intrare	$F(x)$ : funcția de repartiție a variabilei $X$ pe care ne propunem să o simulăm
Pas 1	Se generează o valoare de selecție $u$ uniformă pe $[0, 1]$
Pas 2	Se determină expresia inversei funcției de repartiție $F^{-1}(u)$
Pas 3	Se obține valoarea de selecție dorită $x = F^{-1}(u)$
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$

Metoda inversă (4): Variabile aleatoare continue care pot fi simulate folosind metoda inversă

Repartiția	Densitatea $f$	Inversa $F^{-1}$
$Exp(\lambda)$ , $\lambda > 0$	$f(x) = \lambda e^{-\lambda x}, x > 0$	$x = -\frac{1}{\lambda} \ln(u)$
$Weib(0, 1, \nu)$ , $\nu > 0$	$f(x) = \nu x^{\nu-1} e^{-x^\nu}$	$x = (-\ln(u))^{1/\nu}$
$Cauchy$	$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}, x \in \mathbb{R}$	$x = \tan \pi(u - 1/2)$
$Arcsin$	$f(x) = \frac{1}{\pi} \frac{1}{\sqrt{1-x^2}}, x \in [-1, 1]$	$x = \sin \pi(u - 1/2)$

Metoda inversă (5): Exemplu – simularea unei variabile aleatoare având repartiția  $Exp(\lambda)$ ,  $\lambda > 0$

- Se determină funcția de repartiție a unei v.a.  $X \sim Exp(\lambda)$ :

$$F: \mathbb{R} \rightarrow [0, 1], F(x) = \int_{-\infty}^x f(t) dt = \begin{cases} 1 - e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (10)$$

- Se determină funcția inversă a funcției de repartiție  $F|_{(0, \infty)}$ : pentru  $u \in (0, 1)$ , determinăm  $x > 0$  a.î.  $F(x) = u$ . Obținem inversa funcției  $F|_{(0, \infty)}$  definită prin


$$F^{-1}: (0, 1) \rightarrow (0, \infty), F^{-1}(u) = -\frac{\ln(1-u)}{\lambda} \quad (11)$$

- Din Teorema lui Hincin rezultă că

$$X = -\ln(U)/\lambda, U \sim \mathcal{U}(0, 1) \quad (12)$$

este o v.a. repartizată  $Exp(\lambda)$ .

Metoda inversă (6): Histograma asociată variabilei aleatoare exponențiale



Metoda inversă (7): Simularea unei variabile aleatoare discrete (1)

- Fie v.a. discretă  $X$  definită prin repartiția

$$X: \begin{pmatrix} x_1 & x_2 & \dots & x_m \\ p_1 & p_2 & \dots & p_m \end{pmatrix}, \sum_{i=1}^m p_i = 1, x_1 < x_2 < \dots < x_m. \quad (13)$$

- Funcția de repartiție a v.a.  $X$  este dată de

$$F(x) = \begin{cases} 0 & \text{dacă } x < x_1 \\ p_1 & \text{dacă } x_1 \leq x < x_2 \\ p_1 + p_2 & \text{dacă } x_2 \leq x < x_3 \\ \dots & \dots \\ p_1 + p_2 + \dots + p_k & \text{dacă } x_k \leq x < x_{k+1} \\ \dots & \dots \\ 1 & \text{dacă } x \geq x_m \end{cases} \quad (14)$$

Metoda inversă (8): Simularea unei variabile aleatoare discrete (2)

- ▶ Fie  $(\Omega, \mathcal{B}, P)$  un câmp de probabilitate și

$$X, U : \Omega \rightarrow \mathbb{R}, U \sim \mathcal{U}(0, 1).$$

- ▶ Definim v.a.  $X = Y \circ U$ ,  $X(\omega) = Y(U(\omega)), \forall \omega \in \Omega$ , unde funcția  $Y : [0, 1] \rightarrow \{x_1, x_2, \dots, x_m\}$  este definită prin

$$Y(u) = \begin{cases} x_1, & 0 < u \leq F(x_1) \\ x_2, & F(x_1) < u \leq F(x_2) \\ \dots & \dots \\ x_m, & F(x_{m-1}) < u \leq 1 \end{cases} \quad (15)$$

- ▶ Funcția de probabilitate a v.a.  $X$ ,  $f(x_i) \stackrel{\text{def}}{=} P(X = x_i)$ , devine

$$\begin{aligned} P(X = x_i) &= P(\{\omega \in \Omega \mid Y(U(\omega)) = x_i\}) = \\ &= P(\{\omega \in \Omega \mid F(x_{i-1}) < U(\omega) \leq F(x_i)\}) = \\ &= F(x_i) - F(x_{i-1}) = p_i. \end{aligned} \quad (16)$$

Metoda inversă (10): Exemplu simularea unei v.a. discrete

- ▶ Vrem să generăm o v.a. discretă  $X$  cu repartiția

$$X : \begin{pmatrix} 0 & 1 & 2 \\ 0.3 & 0.2 & 0.5 \end{pmatrix} \quad (18)$$

- ▶ Funcția de repartiție este dată de

$$F(x) = \begin{cases} 0 & \text{dacă } x < 0 \\ 0.3 & \text{dacă } 0 \leq x < 1 \\ 0.5 & \text{dacă } 1 \leq x < 2 \\ 1 & \text{dacă } x \geq 2 \end{cases} \quad (19)$$

- ▶ Se generează valori de selecție asupra v.a.  $X$  conform regulilor

$$X = \begin{cases} 0 & U \leq 0.3 \\ 1 & 0.3 < U \leq 0.5 \\ 2 & 0.5 < U \leq 1 \end{cases} \quad (20)$$

- ▶ Dacă v.a.  $u = 0.78$  atunci obținem valoarea de selecție  $x = 2$ .

Metoda inversă (9): Algoritm pentru simularea unor variabile aleatoare discrete


- ▶ Regula de generare a unei valori de selecție asupra v.a.  $X$ , pornind de la valoarea de selecție  $u$  a v.a.  $U \sim \mathcal{U}(0, 1)$ :


$$X = x_i \text{ dacă } F(x_{i-1}) < u \leq F(x_i) \text{ și } x_0 < x_1 \quad (17)$$


- ▶ Algoritmul pentru simularea v.a.  $X$ :


Intrare	Repartiția variabilei $X$
	$P(X = x_i) = p_i, \sum_{i=1}^m p_i = 1, x_1 < x_2 < \dots < x_m.$
Pas 1	Se generează o valoare de selecție $u$ uniformă pe $[0, 1]$
Pas 2	Dacă $u \leq p_1$ atunci $x = x_1$ Altfel dacă $u \leq p_1 + p_2$ atunci $x = x_2$ Altfel dacă $u \leq p_1 + p_2 + p_3$ atunci $x = x_3$ ... Altfel dacă $u \leq p_1 + p_2 + \dots + p_m$ atunci $x = x_m$
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$

Bibliografie I

 M. Craiu (1998), *Statistică matematică: teorie și probleme*, Editura Matrix Rom, București

 W. L. Martinez, A. R. Martinez (2002), *Computational Statistics Handbook with MATLAB*, Chapman & Hall/CRC, Boca Raton London New York Washington, D.C.

 J. B. Thomas, *Introduction to probability*

 I. Văduva (2004), *Modele de simulare: note de curs*, Editura Universității din București, București

CURS nr. 4  
METODE MODERNE DE CALCUL ȘI SIMULARE

Validarea generatorilor

Metoda amestecării – compunerii

Lect. dr. Bianca Mogoș

◀ ▶ 🔍 ↺ ↻ ⌂

Validarea generatorilor/algoritmilor de simulare a unor variabile aleatoare (1)

- ▶ **Algoritm de simulare:** definirea unei v.a.  $X$  având o funcție de repartiție dată  $F(x) = P(X \leq x), \forall x \in \mathbb{R}$  și observarea variabilei  $X$
- ▶ **Validarea algoritmilor de simulare** înseamnă:
  - ▶ verificarea corectitudinii formale a algoritmilor: se arată că v.a.  $X$  construită în algoritm are funcția de repartiție  $F(x)$
  - ▶ analiza valorilor de selecție asupra v.a.  $X$  returnate de algoritm: pe baza unei mulțimi de selecție  $X_1, X_2, \dots, X_n$ , se verifică ipoteza statistică  $H_0 : X \leftrightarrow F(x)$ .

◀ ▶ 🔍 ↺ ↻ ⌂

Conținut

Validarea generatorilor/algoritmilor de simulare a unor variabile aleatoare

1. Histograma – o validare empirică a algoritmului de simulare
2. Test bazat pe momentele de selecție
3. Testul  $X^2$

Metoda amestecării – compunerii

1. Definiții: amestecare discretă și amestecare continuă
2. Descrierea metodei
3. Algoritm general de amestecare – compunere
4. Fundamentarea matematică a metodei
5. Exemple: Simularea v.a. Laplace și Lomax

◀ ▶ 🔍 ↺ ↻ ⌂

Validarea generatorilor (2): Histograma – o validare empirică a algoritmului de simulare (1)

- ▶ Se verifică intuitiv dacă **repartiția empirică (de selecție)** este asemănătoare cu cea **teoretică**
- ▶ **Histograma** asociată mulțimii de valori de selecție  $x_1, \dots, x_n$  asupra variabilei aleatoare  $X$  având funcția de repartiție  $F(x)$  și densitatea  $f(x)$ :
  - ▶ se determină  $m = \min \{x_1, x_2, \dots, x_n\}$  și  $M = \max \{x_1, x_2, \dots, x_n\}$
  - ▶ se alege  $k$  numărul de intervale/dreptunghiuri ale histogramei
  - ▶ se împarte intervalul  $[m, M]$  în  $k$  intervale egale  $I_i = (a_{i-1}, a_i], 2 \leq i \leq k, I_1 = [a_0, a_1], a_0 = m, a_k = M$
  - ▶ se determină frecvențele relative  $r_i = \frac{f_i}{n}$ , unde  $f_i$ : numărul de valori de selecție ce cad în intervalul  $I_i, 1 \leq i \leq k$
  - ▶ se reprezintă grafic: se iau pe abscisă intervalele  $I_i$  și se construiesc dreptunghiurile având ca bază aceste intervale și ca înălțimi  $h_i = r_i$ .
- ▶ **Înălțimile  $h_i$  ale dreptunghiurilor se scalează a.î.  $h_i \approx f(x), x \in I_i$ .** Definim  $h_i = \frac{f_i}{nl}, l = a_i - a_{i-1}$ .

◀ ▶ 🔍 ↺ ↻ ⌂

### Validarea generatorilor (3): Histograma – o validare empirică a algoritmului de simulare (2)

- ▶ Din *Teorema lui Bernoulli – forma slabă* rezultă că pentru orice  $\epsilon > 0$  avem

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{f_i}{n} - p_i\right| \leq \epsilon\right) = 1, \quad (1)$$

unde  $p_i = P(X \in I_i)$ ,  $I_i = (a_{i-1}, a_i]$

- ▶ Numărul  $k$  de dreptunghiuri ale histogramei se consideră a.î. să se minimizeze *“media pătratelor erorilor (MSE)”* estimatorului  $\hat{f}(x)$  (definit în orice punct  $x$ ) al densității de repartiție  $f(x)$ , definită prin

$$MSE(\hat{f}(x)) = E\left[\left(\hat{f}(x) - f(x)\right)^2\right]. \quad (2)$$

Astfel, avem *Regula Sturges*

$$k = [1 + \log_2 n]. \quad (3)$$

### Validarea generatorilor (4): Test bazat pe momentele de selecție

- ▶ Se determină *momentele teoretice* ale v.a.  $X$ :

$$\mu = E[X] \text{ și } \sigma^2 = \text{Var}(X) \quad (4)$$

- ▶ Pe baza mulțimii de valori de selecție  $\{x_1, x_2, \dots, x_n\}$  se calculează *momentele de selecție*:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \text{ și } s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{X}^2 \quad (5)$$

- ▶ Ca o consecință a *Legii numerelor mari*, putem considera că generatorul este bun dacă pentru  $n$  suficient de mare ( $n > 1000$ )

$$\bar{X} \approx \mu \text{ și } s^2 \approx \sigma^2 \quad (6)$$

### Validarea generatorilor (5): Testul $X^2$ (1)

- ▶ Considerăm *testul de concordanță  $X^2$*  pentru verificarea ipotezei  $H_0 : X \hookrightarrow F(x)$ .
- ▶ Definim *variabila aleatoare  $X^2$* :

$$X^2 = \sum_{i=1}^k \frac{(f_i - np_i)^2}{np_i} \quad (7)$$

unde  $p_1 = F(a_1)$ ,  $p_i = F(a_i) - F(a_{i-1})$ ,  $2 \leq i \leq k-1$ ,  $p_k = 1 - F(a_{k-1})$ .

- ▶ *Observații*:
  - ▶  $f_i : \Omega \rightarrow \{0, 1, \dots, n\}$  este o v.a. *Bin* ( $n, p_i$ )
  - ▶ Mulțimea tuturor valorilor posibile ale lui  $X^2$  se obține făcând ca  $f_1, f_2, \dots, f_k$  să parcurgă toți întregii nenegativi a.î.  $\sum_{i=1}^k f_i = n$
  - ▶ Pentru  $n \rightarrow \infty$ ,  $X^2$  este repartizată  $\chi^2_{k-1}$  (hi pătrat cu  $k-1$  grade de libertate).

### Validarea generatorilor (6): Testul $X^2$ (2)

- ▶ Fie  $\alpha$  *eroarea de tip I*: probabilitatea de a respinge ipoteza nulă  $H_0$  când este adevărată. Valorile clasice pentru  $\alpha$  sunt 0.01, 0.05, 0.1.

- ▶ Se determină  $\alpha$  – *cuantila superioară*, notată  $\chi^2_{k-1, \alpha}$  astfel încât

$$P(X^2 \leq \chi^2_{k-1, \alpha}) = 1 - \alpha \quad (8)$$

- ▶ Ipoteza  $H_0$  se *acceptă* dacă în urma experimentului aleator s-a obținut evenimentul  $\omega \in \Omega$  a.î.:

$$X^2(\omega) \leq \chi^2_{k-1, \alpha}, \quad (9)$$

în caz contrar se respinge.

Metoda compunerii (1): Definiții amestecare discretă și amestecare continuă

- Spunem că funcția de repartiție  $F(x)$  este o *amestecare (compunere sau mixtură) discretă* a mulțimii de funcții de repartiție  $\{F_j(x)\}_{1 \leq j \leq m}$  cu repartiția discretă  $J$  dacă

$$F(x) = \sum_{j=1}^m p_j F_j(x) \text{ și } J: \begin{pmatrix} 1 & 2 & \dots & m \\ p_1 & p_2 & \dots & p_m \end{pmatrix}, \sum_{j=1}^m p_j = 1 \quad (10)$$

- Spunem că funcția de repartiție  $F(x)$  este o *amestecare continuă* a familiei de funcții de repartiție  $\{G(x, Y)\}_{Y \in \mathbb{R}}$ , cu funcția de repartiție continuă  $H(y)$  a lui  $Y$  dacă este de forma

$$F(x) = \int_{\mathbb{R}} G(x, y) dH(y). \quad (11)$$

Metoda compunerii (2): Descrierea metodei

- Fie  $X$  o v.a. cu funcția de repartiție  $F(x)$  definită în (10) și  $X_j, 1 \leq j \leq m$  v.a. având funcțiile de repartiție  $F_j(x)$ . Atunci

$$X = X_j \text{ cu probabilitatea } p_j \quad (12)$$

- Fie  $X$  o v.a. cu funcția de repartiție  $F(x)$  definită în (11) și  $Z_Y, Y \in \mathbb{R}$  v.a. având funcțiile de repartiție  $G(x, Y)$ , unde  $Y$  are funcția de repartiție  $H(y)$ . Atunci

$$X = Z_Y \text{ unde } y \text{ este generat cu funcția de repartiție } h(y) \quad (13)$$

- În definiția amestecării se pot considera în loc de funcții de repartiție, densități de repartiție și formulele devin

$$f(x) = \sum_{i=1}^m p_i f_i(x), \text{ respectiv } f(x) = \int_{\mathbb{R}} g(x, y) h(y) dy \quad (14)$$

Metoda compunerii (3): Algoritm pentru simularea unei variabile aleatoare bazat pe noțiunea de amestecare discretă

Intrare	Se cunosc algoritmi pentru simularea v.a. $X_j$ având funcțiile de repartiție $F_j(x)$ Repartiția v.a. discrete $J: P(J = j) = p_j, \sum_{j=1}^m p_j = 1$
Pas 1	Se generează un indice $j$ având repartiția $J$
Pas 2	Se generează $x_j$ cu funcția de repartiție $F_j(x)$
Pas 3	Se definește $x = x_j$
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$ având funcția de repartiție $F(x)$

Metoda compunerii (4): Algoritm pentru simularea unei variabile aleatoare bazat pe noțiunea de amestecare continuă

Intrare	Se cunosc algoritmi pentru simularea v.a. $Z_Y$ având funcțiile de repartiție în familia $\{G(x, Y)\}_{Y \in \mathbb{R}}$ Se cunoaște un algoritm pentru simularea v.a. $Y$ cu funcția de repartiție $H(y)$
Pas 1	Se generează $y$ cu funcția de repartiție $H(y)$
Pas 2	Se generează $z_y$ cu funcția de repartiție $G(x, y)$
Pas 3	Se definește $x = z_y$
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$ având funcția de repartiție $F(x)$

Metoda compunerii (5): Exemplu amestecare discretă

Metoda compunerii (6): Algoritmul pentru simularea v.a. X având repartiția Laplace

- Fie  $X$  variabila având repartiția Laplace a cărei densitate de repartiție este

$$f(x) = \frac{\lambda}{2} e^{-\lambda|x|}, x \in \mathbb{R}, \lambda > 0 \tag{15}$$

- Observăm că

$$f(x) = p_1 f_1(x) + p_2 f_2(x), p_1 = p_2 = \frac{1}{2}$$

unde

$$f_1(x) = \begin{cases} 0 & \text{dacă } x \leq 0 \\ \lambda e^{-\lambda x} & \text{dacă } x > 0 \end{cases}, f_2(x) = \begin{cases} \lambda e^{\lambda x} & \text{dacă } x \leq 0 \\ 0 & \text{dacă } x > 0 \end{cases}$$

Intrare	V.a. $X_1 \sim \text{Exp}(\lambda)$ cu densitatea de repartiție $f_1(x)$ și V.a. $X_2 = -X_1$ cu densitatea de repartiție $f_2(x)$
Pas 1	Se generează val. de selecție $u$ a v.a. $U \sim \mathcal{U}(0, 1)$
Pas 2	Dacă $u \leq 0.5$ atunci mergi la Pas 3; altfel mergi la Pas 4
Pas 3	$s = 1$ ; mergi la Pas 5
Pas 4	$s = -1$
Pas 5	Se generează val. de selecție $x_1$ a v.a. $X_1 \sim \text{Exp}(\lambda)$
Pas 6	Se definește $x = s x_1$
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$ .

Metoda compunerii (7): Exemplu amestecare continuă

Bibliografie I


- Fie variabila  $X, X > 0$ , durata de funcționare a unui aparat, reprezentată Exponențial( $\eta\lambda$ ), unde
  - $\lambda$  este un parametru determinat de producător, iar
  - $\eta$  este un parametru aleator care indică influența mediului în care este studiat aparatul.
- Repartiția de probabilitate a lui  $\eta$  este de tip  $\text{Gamma}(0, b, a)$ :


$$h(\eta) = \begin{cases} 0, & \text{dacă } x < 0 \\ \frac{b^a}{\Gamma(a)} \eta^{a-1} e^{-b\eta}, & \text{altfel} \end{cases} \tag{16}$$


- Densitatea de repartiție a lui  $X$ , pentru  $x \geq 0$  va fi de forma

$$f(x) = \int_0^\infty \eta \lambda e^{-\lambda \eta x} \frac{b^a}{\Gamma(a)} \eta^{a-1} e^{-b\eta} d\eta = \frac{a\theta}{(\theta x + 1)^{a+1}}, \text{ unde } \theta = \frac{\lambda}{b} \tag{17}$$

- Repartiția având densitatea (17) se numește *repartiție Lomax*.

 M. Craiu (1998), *Statistică matematică: teorie și probleme*, Editura Matrix Rom, București

 W. L. Martinez, A. R. Martinez (2002), *Computational Statistics Handbook with MATLAB*, Chapman & Hall/CRC, Boca Raton London New York Washington, D.C.

 I. Văduva (2004), *Modele de simulare: note de curs*, Editura Universității din București, București



Intrare	V.a. $N$ , v.a. $S_1, S_2, \dots, S_n \in S$ , predicatul $\mathcal{P}(S_1, S_2, \dots, S_n)$ , funcția $\psi(S_1, S_2, \dots, S_n)$
	Repetă Pas 1 – Pas 3 până când $\mathcal{P}(S_1, S_2, \dots, S_n) = true$
Pas 1	Se simulează o valoare $n$ a lui $N$
Pas 2	Se simulează valorile de selecție $S_1, S_2, \dots, S_n \in S$
Pas 3	Se verifică dacă $\mathcal{P}(S_1, S_2, \dots, S_n) = true$
Pas 4	Se consideră $x = \psi(S_1, S_2, \dots, S_n)$ .
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$

Teoremă (Teorema înfășurătoare)

Fie dată o variabilă aleatoare  $X$  care are densitatea de repartiție  $f(x), x \in \mathbb{R}$  pe care dorim să o simulăm. Fie  $Y$  o altă variabilă aleatoare ce știm să o simulăm și a cărei densitate de repartiție este  $h(x)$  astfel încât  $f, h$  au același suport  $S$  (adică iau valori diferite de zero pe aceeași mulțime  $S \subseteq \mathbb{R}$ ). Presupunem că există o constantă  $\alpha, 0 < \alpha < \infty$ , astfel încât  $f(x) \leq \alpha h(x), \forall x \in S$ . În aceste condiții, dacă  $U$  este o variabilă uniformă pe  $[0,1]$  independentă de  $Y$  atunci densitatea de repartiție a variabilei  $Y$  condiționată de  $0 \leq U \leq f(Y)/(\alpha h(Y))$  este  $f$ .

Observații (2)

Demonstrația teoremei înfășurătoare (3)

- Fie  $(\Omega, \mathcal{B}, P)$  un câmp de probabilitate
- Definim

$$\Omega_1 = \{\omega \in \Omega \mid 0 \leq U(\omega) \leq f(Y(\omega))/(\alpha h(Y(\omega)))\} \quad (3)$$

și

$$X : \Omega_1 \rightarrow \mathbb{R}, X = Y|_{\Omega_1} \quad (4)$$

- $f(x) = F'(x), F(x) = P(X \leq x) \stackrel{\text{def}}{=} P(Y \leq x | \Omega_1)$
- $(\exists) \epsilon_0$  a.î.  $\frac{p_A}{p_{\Omega_1}} - \epsilon_0 < \frac{k_A}{k_{\Omega_1}} < \frac{p_A}{p_{\Omega_1}} + \epsilon_0$ , unde
  - $p_A = P(Y \leq x \cap \Omega_1), p_{\Omega_1} = P(\Omega_1)$
  - $k_A, k_{\Omega_1}$  reprezintă numărul de apariții ale evenimentelor  $A$ , respectiv  $\Omega_1$  pentru un număr suficient de mare de repetări ale experimentului aleator.

- Trebuie demonstrat că

$$P(Y \leq x | 0 \leq U \leq f(Y)/(\alpha h(Y))) = F(x) = \int_{-\infty}^x f(v) dv \quad (5)$$

- Considerăm evenimentele

$$A = \{Y \leq x\} \text{ și } \Omega_1 = \{0 \leq U \leq f(Y)/(\alpha h(Y))\} \quad (6)$$

- Din (5) și (6) rezultă că trebuie să calculăm  $P(A|\Omega_1)$  având definiția

$$P(A|\Omega_1) = \frac{P(A \cap \Omega_1)}{P(\Omega_1)} \quad (7)$$

Demonstrația teoremei înfășurătoarei (4)

Algoritm pentru simularea unei v.a. bazat pe teorema înfășurătoarei (5)

► Calculăm  $P(\Omega_1)$ :

$$\begin{aligned} P(\Omega_1) &= \int_{-\infty}^{+\infty} \left[ \int_0^{f(v)/(\alpha h(v))} du \right] h(v) dv = \\ &= \int_{-\infty}^{+\infty} \frac{f(v)}{\alpha h(v)} h(v) dv = \frac{1}{\alpha}, \alpha > 1 \end{aligned} \tag{8}$$

► Astfel,  $P(A|\Omega_1)$  devine:

$$\begin{aligned} P(A|\Omega_1) &= \alpha \int_{-\infty}^x \left[ \int_0^{f(v)/(\alpha h(v))} du \right] h(v) dv = \\ &= \alpha \int_{-\infty}^x \frac{f(v)}{\alpha h(v)} h(v) dv = \int_{-\infty}^x f(v) dv \end{aligned} \tag{9}$$

Intrare	Știm să generăm v.a. $Y$ având densitatea de repartiție $h(y)$
Pas 1	Se caută o constantă $\alpha$ a. î. $f(x) \leq \alpha h(x), \forall x \in S$  Repetă Pas 2 – Pas 4 până când $u \leq f(y)/\alpha h(y)$ , cu $u$ și $y$ valori de selecție obținute în pașii indicați
Pas 2	Se simulează o valoare de selecție $u$ a v.a. $U \sim \mathcal{U}(0,1)$
Pas 3	Se simulează o valoare de selecție $y$ a v.a. $Y$ cu dens. $h(y)$
Pas 4	Se verifică dacă $u \leq f(y)/\alpha h(y)$
Pas 5	Se consideră $x = y$ .
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$ având densitatea de repartiție $f(x)$

Simularea variabilei aleatoare normale (6)

Simularea variabilei aleatoare normale (7)

► Spunem că  $X \sim \mathcal{N}(\mu, \sigma)$  dacă  $X$  are densitatea de repartiție

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \tag{10}$$

► Se va prezenta un algoritm de simulare a variabilei aleatoare  $Z \sim \mathcal{N}(0,1)$  bazat pe o metodă de compunere - respingere. Se deduce ușor un algoritm de simulare a v.a.  $X \sim \mathcal{N}(\mu, \sigma)$  folosind relația:

“Dacă  $Z \sim \mathcal{N}(0,1)$  atunci  $X = \sigma Z + \mu$  este o v.a.  $X \sim \mathcal{N}(\mu, \sigma)$ ”

► Considerăm v.a.  $X_1$  și  $X_2 = -X_1$  având densitățile de repartiție

$$f_1(x) = \begin{cases} 0 & \text{dacă } x \leq 0 \\ \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} & \text{dacă } x > 0 \end{cases} \tag{11}$$

și respectiv,

$$f_2(x) = \begin{cases} \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} & \text{dacă } x \leq 0 \\ 0 & \text{dacă } x > 0 \end{cases} \tag{12}$$

► Densitatea de repartiție a v.a.  $Z \sim \mathcal{N}(0,1)$  se poate scrie sub forma

$$f(x) = \frac{1}{2} f_1(x) + \frac{1}{2} f_2(x), \tag{13}$$

adică este o compunere discretă a densităților  $f_1(x)$  și  $f_2(x)$ .

Simularea variabilei aleatoare  $X_1$  (8)

Aplicăm teorema înfășurătoarei pentru a genera v.a.  $X_1$  cu densitatea de repartiție  $f_1(x)$ :

- ▶ se consideră ca înfășurătoare densitatea de repartiție  $h(x)$  a v.a.  $Y \sim \text{Exp}(1)$
- ▶ raportul  $r(x) = \frac{f_1(x)}{h(x)} = \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2} + x}$
- ▶ ecuația  $r'(x) = 0$  are soluția  $x_0 = 1$  care este punct de maxim pentru funcția  $r(x)$ . Rezultă, de aici,

$$r(x) \leq r(x_0) = \sqrt{\frac{2e}{\pi}}. \tag{14}$$

- ▶ considerăm constanta  $\alpha = \sqrt{\frac{2e}{\pi}}$ . De asemenea, se observă că densitățile  $f_1(x)$  și  $h(x)$  au același suport  $S = (0, \infty)$ .

Algoritmul pentru simularea variabilei aleatoare normale  $Z \sim N(0, 1)$  (9)

Intrare	Pp. că știm să generăm v.a. $Y \sim \text{Exp}(1)$ .
	Repetă Pas 1 – Pas 3 până când $u \leq e^{-\frac{y^2}{2} + y - 0.5}$ , cu $u$ și $y$ valori de selecție generate în pașii indicați.
Pas 1	Se simulează o valoare de selecție $u$ a v.a. $U \sim \mathcal{U}([0, 1])$
Pas 2	Se simulează o valoare de selecție $y$ a v.a. $Y \sim \text{Exp}(1)$
Pas 3	Se verifică dacă $u \leq e^{-\frac{y^2}{2} + y - 0.5}$
Pas 4	Se generează $u_1$ val. de selecție a v.a. $U_1 \sim \mathcal{U}([0, 1])$ .
Pas 5	Dacă $u_1 \leq 0.5$ atunci mergi la Pas 6; altfel mergi la Pas 7
Pas 6	Se consideră $z = y$ . Mergi la Ieșire.
Pas 7	Se consideră $z = -y$ .
Ieșire	Valoarea de selecție, $z$ , a v.a. $Z \sim N(0, 1)$

Teorema a doua de respingere (1)

Teoremă

Fie  $X$  o v.a. având funcția de repartiție de forma

$$F(x) = c \int_{-\infty}^x Q(\phi(y)) dR(y) \tag{15}$$

unde  $Q(z)$  este funcția de repartiție a unei v.a.  $Z, Z \in [0, M]$ ,  $\phi(y)$  este o funcție ce ia valori în intervalul  $[0, M]$  (unde  $M$  poate lua și valoarea  $\infty$ ), iar  $R(y)$  este funcția de repartiție a unei v.a.  $Y, Y \in \mathbb{R}$ , iar variabilele  $Z, Y$  sunt independente stochastic. Atunci funcția de repartiție a variabilei  $Y$  condiționată de  $Z \leq \phi(Y)$  este  $F(x)$ .

Teorema a doua de respingere - observații (2)

- ▶ Probabilitatea de acceptare este  $p_a = P(Z \leq \phi(Y)) = \frac{1}{c}$ , unde  $c$  este o constantă de normare cu formula

$$c = \left[ \int_{-\infty}^{+\infty} Q(\phi(x)) dR(x) \right]^{-1} \tag{16}$$

- ▶ Condiția (15) se poate scrie în termeni de densități de repartiție:

$$f(x) = cQ(\phi(x))r(x), r(x) = R'(x). \tag{17}$$

- ▶ O formă duală a teoremei se obține dacă  $F(x)$  este de forma

$$F(x) = c \int_{-\infty}^x (1 - Q(\phi(y))) dR(y) \tag{18}$$

pentru  $c = \left[ \int_{-\infty}^{+\infty} (1 - Q(\phi(x))) dR(x) \right]^{-1}$ ; predicatul devine  $\{Z \geq \phi(Y)\}$ .

Teorema a doua de respingere - exemplu (3)

- Fie  $X$  o v.a. având densitatea de repartiție

$$f(x) = c\mu(1 - e^{-\lambda x})e^{-\mu x}, x \geq 0 \tag{19}$$

- Variabila  $X$  se poate simula folosind un algoritm de respingere, pentru

$$\phi(x) = x, Q(z) = 1 - e^{-\lambda z} \text{ și } r(x) = \mu e^{-\mu x} \tag{20}$$

- Se obține  $c = \left[ \int_0^\infty \mu(1 - e^{-\lambda x})e^{-\mu x} dx \right]^{-1} = \left[ \frac{\lambda}{\lambda + \mu} \right]^{-1}$

Teorema șirului descendent (2)

3. Dacă subșirul descendent este  $Z_0 \geq Z_1 \geq \dots \geq Z_{K-1} < Z_K$  atunci

$$F(x) = P(Z_0 \leq x | K = \text{nr. impar}) = \frac{1}{p_a} \int_{-\infty}^x e^{-G(t)} dG_0(t), \tag{23}$$

unde  $p_a$  este constanta de normare dată prin

$$p_a = \left[ \int_{-\infty}^\infty e^{-G(t)} dG_0(t) \right]. \tag{24}$$

Teorema șirului descendent (1)

Presupunem date variabilele aleatoare  $Z_i, i \geq 1$  cu funcțiile de repartiție  $G(x)$  și  $Z_0$  cu funcția de repartiție  $G_0(x)$ , independente stochastic. Atunci sunt adevărate afirmațiile:

1. Dacă  $x$  este fixat și numărul  $k$  este fixat atunci

$$P(x \geq Z_1 \geq Z_2 \geq \dots \geq Z_{k-1} < Z_k) = \frac{[G(x)]^{k-1}}{(k-1)!} - \frac{[G(x)]^k}{k!}. \tag{21}$$

2. Dacă  $x$  este fixat și  $K$  este indicele aleator la care se "rupe" subșirul descendent (ca la punctul 1.) atunci

$$P(K = \text{nr. impar}) = e^{-G(x)}. \tag{22}$$

Algoritm de simulare a unei v.a. bazat pe teorema șirului descendent (3)

Intrare	Pp. că știm să generăm v.a. $Z_i \hookrightarrow G(x), i \geq 1$ și $Z_0 \hookrightarrow G_0(x)$
	Repetă Pas 1 – Pas 2 până când $K = \text{nr. impar}$
Pas 1	Se generează val. de selecție $z_0$ a v.a. $Z_0 \hookrightarrow G_0(x)$ și $z_1$ a v.a. $Z_1 \hookrightarrow G(x)$ . Se ia $z^* = z_0, K = 1$ ;
Pas 2	Repetă Pas 3 - Pas 4 cât timp $z_0 \geq z_1$
Pas 3	$K = K + 1; z_0 = z_1$
Pas 4	Se generează o val. de selecție $z_1$ a v.a. $Z_1 \hookrightarrow G(x)$
Pas 5	Se consideră $x = z^*$
Ieșire	Valoarea de selecție, $x$ , a v.a. $X \hookrightarrow F(x)$

- ▶ Cu cât  $p_a$  este mai mare cu atât mai repede va fi acceptată o val. de selecție a v.a.  $Z_0$  (când  $K = \text{nr. impar}$ )
- ▶ Performanța algoritmului depinde de numărul de valori  $Z_i$  generate pentru a obține un  $Z_0$  acceptat
- ▶ Se arată că valoarea medie a numărului de val. de selecție  $Z_i, i \geq 1$  necesare până la acceptarea unui  $Z_0$ , notat  $N^*$  este

$$E[N^*] = \frac{1}{p_a} \left( 1 + \int_{-\infty}^{+\infty} e^{G(x)} dG_0(x) \right) \quad (25)$$

- ▶ Considerăm în Teorema șirului descendent, variabilele  $Z_i, i \geq 0$  repartizate  $\mathcal{U}([0,1])$  și independente stochastic.

- ▶ Avem

$$P(Z_0 \leq x | K = \text{nr. impar}) = \frac{1}{p_a} \int_0^x e^{-x} dx; \text{ unde} \quad (26)$$

$$p_a = \int_0^1 e^{-x} dx = 1 - e^{-1}$$

- ▶ Astfel,  $Z_0$  acceptat are funcția de repartiție

$$F(x) = \begin{cases} 0, & \text{dacă } x < 0 \\ \frac{1-e^{-x}}{1-e^{-1}}, & \text{dacă } 0 \leq x \leq 1 \\ 1, & \text{dacă } x > 1 \end{cases} \quad (27)$$

adică repartiția exponențială de parametru 1, trunchiată pe intervalul  $[0,1]$ .

## Bibliografie I



I. Văduva (2004), *Modele de simulare: note de curs*, Editura Universității din București, București

CURSUL nr. 8  
METODE MODERNE DE CALCUL ȘI SIMULARE

## Modele de simulare

Lect. dr. Bianca Mogos

1. Principiile modelării și simulării
  - 1.1 Noțiuni de bază – Definiție model
  - 1.2 Introducerea noțiunii de simulare
  - 1.3 Avantajele și dezavantajele utilizării simulării
  - 1.4 Aplicații ale simulării
  - 1.5 Schema de modelare și simulare
  - 1.6 Construcția unui model de simulare.
  - 1.7 Exemplu: Modelul de simulare asociat unui sistem de așteptare
2. Generalități despre limbajul GPSS
  - 2.1 Descriere generală a limbajului GPSS
  - 2.2 Structura instrucțiunii GPSS
  - 2.3 Blocuri de creare și distrugere de tranzații
  - 2.4 Blocuri de acțiune
  - 2.5 Blocuri pentru obținerea de statistici
  - 2.6 Blocuri de control logic al tranzațiilor
  - 2.7 Blocuri de modificare a caracteristicilor tranzațiilor și a valorilor unor entități de referință

### 1.1 Noțiuni de bază – Definiție model (1)

- ▶ Oamenii de știință și inginerii încearcă *să înțeleagă, să dezvolte și să optimizeze sisteme*.
- ▶ O *problemă* care apare în analiza unui sistem este *complexitatea* acestuia.
- ▶ Folosirea unor *descrieri simplificate* ale sistemelor – *modelele* – reprezintă o *soluție* care permite abordarea unor sisteme complexe.
- ▶ *Definiție*: Pentru un observator  $B$ , un obiect  $A^*$  este un *model* al obiectului  $A$  dacă  $B$  poate folosi  $A^*$  pentru a răspunde întrebărilor care îl interesează referitoare la  $A$ .
- ▶ *Modelul cel mai bun* este *modelul cel mai simplu* care își îndeplinește obiectivul de a ne ajuta să înțelegem un sistem complex și de a rezolva anumite probleme.

## 1.2 Introducerea noțiunii de simulare

- ▶ Cuvântul *simulare* este de origine latină și înseamnă *capacitatea de a reproduce ceva*.
- ▶ Termenul de simulare a fost introdus de *John von Neumann* la începutul anilor '40.
- ▶ *Modelul de simulare* este o extindere a unui model matematic prin descrierea relațiilor dintre componentele modelului.
- ▶ *Simularea* reprezintă aplicarea unui model (numit model de simulare) pentru a descrie comportamentul și evoluția unui sistem real în timp.

### 1.3 Avantajele și dezavantajele utilizării simulării (1)

### Avantajele obtinute datorită realizării unui studiu de simulare

- ▶ Simularea furnizează o modalitate *neconstituitoare* și *neriscantă* de realizare a unor teste referitoare la funcționalitatea unui sistem.
- ▶ Simularea permite *precizarea* comportamentului unui sistem pentru diferite ipoteze/variaabile de intrare ale sistemului și *reducerea riscului* de a lua o decizie greșită.
- ▶ Un model de simulare permite *analiza variabilității proceselor* dintr-un sistem, ne poate ajuta să înțelegem cum interacționează între ele mai multe componente ale sistemului și cum poate afecta interacțiunea dintre ele performanța sistemului.
- ▶ Simularea dă *posibilitatea de explorare* a mai multor căi alternative.
- ▶ Dezvoltarea unei aplicații de simulare poate determina *o mai bună înțelegere* a sistemului studiat.



## 1.4 Aplicații ale simulării

- ▶ Simularea unui aeroport având ca scop minimizarea întârzierilor provocate de aglomerări
- ▶ Simularea spațiului aerian având ca scop utilizarea optimă a acestuia
- ▶ Simularea în domeniul medical a numărului de cadre medicale necesar la momente diferite de timp
- ▶ Planificarea strategică a operațiilor realizate într-o bancă și realizarea unei topologii optime a cursurilor băncii
- ▶ Simularea unei linii de producție pentru a estima cantitatea de materie primă necesară și pentru a prezice profitul obținut



### 1.3 Avantajele și dezavantajele utilizării simulării (2)

### Dezavantajele unui studiu de simulare

- ▶ Simularea folosește un model – reprezentând o descriere simplificată a sistemului real – care nu poate surprinde întreaga complexitate a unui sistem real.



## 1.5 Schema de modelare și simulare

### Definitii

- Definirea problemei pe care ne propunem să o rezolvăm sau a întrebării la care trebuie să răspundem
- Definirea sistemului – o colecție de obiecte/entități ale căror proprietăți vrem să le studiem

### Analiza sistemului

- Identificarea părților sistemului relevante pentru problemă

## Modelarea

- ▶ Dezvoltarea modelului asociat sistemului

### Simularea

- ▶ Dezvoltarea unei strategii pentru rezolvarea problemei

## Validarea

- Verificarea dacă strategia elaborată în pasul de simulare rezolvă problema unui sistem real





## 1.6 Construcția unui model de simulare (1) – Ceasul simulării

- ▶ *Ceasul simulării*: asigură *ordonarea* corectă în timp a *evenimentelor* create de model și uneori ajută la implementarea condiției de terminare a simulării.
- ▶ *Evenimentele* corespund unor modificări în sistem; de exemplu modificarea valorilor unor variabile care se calculează sau se generează prin instrucțiuni ale modelului
- ▶ Ceasul pornește cu valoarea zero la începutul simulării; simularea se realizează până când ceasul atinge o valoare dată inițial  $T_{max}$
- ▶ O *clasificare* a ceasului simulării
  - ▶ *ceas cu creștere constantă*: ceasul crește cu o unitate de timp  $c$  constantă, apoi se prelucrează toate evenimentele apărute pe intervalul de timp de lungime  $c$
  - ▶ *ceas cu creștere variabilă*: ceasul crește cu valoarea ce corespunde apariției primului eveniment următor, apoi programul prelucrează evenimentul și se reia ciclul simulării

## 1.6 Construcția unui model de simulare (3) – Algoritmul simulării

- ▶ *Algoritmul simulării* actualizează agenda prin *interacțiunea acesteia cu ceasul*
- ▶ Într-un *ciclu al simulării* ceasul este actualizat, se selectează din agenda *A* evenimentele care fac parte din AEC și se prelucrează aceste evenimente până când AEC devine vidă.
- ▶ Atunci ceasul este crescut din nou și se reia *ciclu de simulare*.

## 1.6 Construcția unui model de simulare (2) – Agenda simulării

- ▶ *Agenda* conține elementele/variabilele asociate evenimentelor memorate de modelul de simulare
- ▶ Agenda *A* se compune din două părți:
  - ▶ *AEC – agenda evenimentelor curente* (care au timpul de apariție egal cu valoarea ceasului)
  - ▶ *AEV – agenda evenimentelor viitoare* (care au timpul de apariție ulterior valorii curente a ceasului)
- ▶ Algoritmul de simulare prelucrează numai evenimentele din AEC; prelucrarea unui eveniment înseamnă fie determinarea apariției unui nou eveniment (ce se memorează în AEV) sau modificarea unei stări, fie distrugerea unui eveniment (ștergerea) lui din agendă.

## 1.7 Exemplu: Modelul de simulare asociat unui sistem de așteptare (1)

- ▶ *Sistemul de așteptare* este o parte a lumii reale în care se produc *aglomerări*.
- ▶ *Entitățile componente ale sistemului*:
  - ▶ *clienții* care sosesc în sistem
  - ▶ *stațiile de servire* (care servesc după anumite reguli clienții)
- ▶ Dacă sosesc mulți clienți și stațiile de servire nu pot să îi servească se formează *cozi de așteptare* în sistem.
- ▶ Administratorul sistemului trebuie să construiască sistemul a.î. nici clienții să nu *aștepte* mult până primesc serviciul, dar nici stațiile să nu *lenevească*, deoarece ar putea produce pierderi proprietarului.
- ▶ *Aplicații ale sistemelor de așteptare*: în comerț, în managementul sistemelor de comunicații și de transport, dar și în dirijarea și funcționarea în timp real a rețelelor de calculatoare.

## 1.7 Exemplu: Modelul de simulare asociat unui sistem de așteptare (2)

Un model de așteptare conține de obicei următoarele elemente:

- ▶ *Variabile de intrare (cunoscute, de obicei aleatoare):*
  - ▶ *TI*: timp de intersosire al clienților
  - ▶ *TS*: timp de servire al unui client
- ▶ *Variabile de ieșire (necunoscute):*
  - ▶ *TA*: timp de așteptare (sau *LC*: lungimea cozii)
  - ▶ *TL*: timp de lenevire (sau *NSL*: numărul stațiilor care lenevesc)

*Scopul modelului:* cunoscând repartițiile de probabilitate ale variabilelor *TI* și *TS* vrem să obținem informații despre *TA* și *TL* și să se stabilească cum trebuie să se realizeze *TS* a.î. să se optimizeze o anumită funcție criteriu.

## 2.1 Descriere generală a limbajului GPSS

- ▶ *Limbajele de simulare* sunt limbaje de programare care implementează elementele de bază ale simulării: *ceasul simulării* și *gestionarea memoriei*.
- ▶ *Utilizatorul* se ocupă de *descrierea evenimentelor* și prelucrarea lor.
- ▶ Exemplu de limbaj de simulare: *GPSS (General Purpose System Simulator)*
- ▶ *Entități ale modelului:*
  - ▶ *Blocuri:* entități care descriu activități
  - ▶ *Tranzacții:* sunt elemente create printr-un bloc *GENERATE* care parcurg blocurile modelului/sistemului secvențial și în funcție de acțiunea blocurilor accesate.
  - ▶ *Stații de servire sau facilități:* resurse care oferă un singur serviciu (adică unei singure tranzacții)
  - ▶ *Multistații de serviciu sau depozite:* resurse care oferă servicii mai multor tranzacții simultan
  - ▶ *Entități de calcul:* variabile, funcții
  - ▶ *Entități statistice:* cozi, histogramme

## 2.2 Structura instrucțiunii GPSS

Etichetă	Numele blocului (Cuvânt cheie)	Parametri (separați prin virgulă)
Opțională (pt. referiri)	Verb imperativ indică acțiunea blocului	A,B,C,...

## 2.3 Blocuri de creare și distrugere de tranzacții

- ▶ *GENERATE* – creează tranzacții. Are forma generală:  
*GENERATE A,B,C,D,E*
  - ▶ *A* – intervalul mediu între sosiri
  - ▶ *B* – abaterea; lungimea intervalului de timp între generarea a două tranzacții consecutive este o valoare întreagă a unei variabile aleatoare uniform distribuite pe interval  $[A - B, A + B]$
  - ▶ *C* – momentul creării primei tranzacții
  - ▶ *D* – numărul maxim de tranzacții generate
  - ▶ *E* – prioritatea (valoare implicită = 0)
- ▶ *TERMINATE* – determină distrugerea unei tranzacții. Are forma generală:  
*TERMINATE A*
  - ▶ *A* – decrementează parametrul dat la *START* (în fereastra care apare în urma rulării programului). De exemplu dacă avem "*START nr*" atunci, în momentul în care o tranzacție accesează blocul "*TERMINATE A*", "*nr*" devine "*nr = nr - A*". Programul rulează cât timp "*nr > 0*".

## 2.4 Blocuri de acțiune (1)

- ▶ *SEIZE/RELEASE* – se folosesc împreună și determină ocuparea/eliberarea unei resurse denumită *facilitate*; de asemenea creează o facilități, numele facilității fiind dat ca parametru. Au forma generală:  
SEIZE resursă  
.....  
RELEASE resursă
  - ▶ resursă – este numele facilității
- ▶ *ADVANCE* – determină oprirea/blocarea tranzacției care accesează acest bloc un interval de timp dat de parametri. Are forma generală:  
ADVANCE A,B
  - ▶ A – timp mediu de blocare/întârziere a tranzacției
  - ▶ B – abaterea

## 2.4 Blocuri de acțiune (2.1)

- ▶ *ENTER/LEAVE* – se folosesc împreună și determină ocuparea/eliberarea unei/mai multor componente dintr-o resursă denumită *punct de servire cu mai multe stații* sau *entitate de depozitare*.
- ▶ *Capacitatea* (numărul de componente care pot fi ocupate) *resurse* și *entitate asociată* sunt definite prin blocul *STORAGE*.
- ▶ *Forma generală a blocurilor* este descrisă în slide-ul următor.

## 2.4 Blocuri de acțiune (2.2)

- ▶ Sintaxa blocurilor *STORAGE/ENTER/LEAVE*:  
resursă STORAGE capacitate  
.....  
GENERATE A1,B1  
.....  
ENTER resursă,spații\_ocupate  
.....  
LEAVE resursă,spații\_eliberate  
.....  
TERMINATE A2
  - ▶ resursă – este numele punctului de servire cu mai multe stații sau a entității de depozitare
  - ▶ spații\_ocupate – numărul de componente ocupate din entitatea "resursă" când o tranzacție accesează blocul ENTER
  - ▶ spații\_eliberate – numărul de componente eliberate din entitatea "resursă" când o tranzacție accesează blocul LEAVE
  - ▶ spații\_ocupate, spații\_eliberate – trebuie să ia valori mai mici sau egale decât valoarea parametrului "capacitate"

## 2.4 Blocuri de acțiune (3)

- ▶ *PREEMPT/RETURN* – se folosesc împreună și determină ocuparea/eliberarea unei facilități; ocuparea facilității are loc în funcție de prioritatea asociată tranzacției. Au forma generală:  
PREEMPT resursă,prioritate,blocTransfer  
.....  
RETURN resursă
  - ▶ resursă – este numele facilității
  - ▶ prioritate – poate fi PR sau poate să lipsească.
    - ▶ Dacă este PR atunci o tranzacție care accesează un bloc PREEMPT poate îndepărta tranzacția care ocupă deja facilitatea (pe care a ocupat-o printr-un bloc SEIZE sau PREEMPT) în funcție de prioritate (tranzacția având prioritatea mai mare va ocupa în continuare facilitatea).
    - ▶ Dacă PR lipsește atunci PREEMPT poate îndepărta doar o tranzacție care a ocupat facilitatea prin blocul SEIZE, în caz contrar tranzacția va fi introdusă în coada de așteptare.
  - ▶ blocTransfer – este opțional și reprezintă blocul la care este dirijată tranzacția care ocupa inițial facilitatea. Dacă lipsește atunci tranzacția va fi introdusă în coada de așteptare și după eliberarea facilității va primi în continuare serviciul.

## 2.5 Blocuri pentru obținerea de statistici (1)

- ▶ **QUEUE/DEPART** – se folosesc împreună și permit obținerea de statistici/informații referitoare la coada de așteptare. Au forma generală:  
QUEUE coada  
.....  
DEPART coada
  - ▶ coada – este numele cozii de așteptare
- ▶ **ATENȚIE:** blocurile **QUEUE/DEPART** NU determină crearea unei cozi de așteptare, permit doar obținerea de informații referitoare la coada de așteptare, care este creată implicit de către limbajul GPSS în momentul în care o tranzacție accesează unul dintre blocurile de acțiune **SEIZE**, **ENTER** sau **PREEMPT**

## 2.5 Blocuri pentru obținerea de statistici (2.2)

Construcția histogramei este iterativă:

- ▶ în momentul în care o tranzacție accesează blocul "TABULATE etHist", se calculează expresia definită prin parametrul "A" al histogramei cu numele "etHist";
- ▶ valoarea expresiei reprezintă o valoare de selecție, notată,  $x_i$  pentru tranzacția  $i$ , asupra unei variabile aleatoare;
- ▶ la fiecare accesare a blocului "TABULATE" de către o tranzacție se actualizează mulțimea valorilor de selecție,  $S_n = S_{n-1} \cup \{x_n\}$ , unde  $S_{n-1} = \{x_1, x_2, \dots, x_{n-1}\}$  este mulțimea de valori de selecție obținută pentru primele  $n - 1$  tranzacții, iar  $x_n$  este valoarea expresiei date prin parametrul A calculată pentru tranzacția a  $n - a$  care accesează blocul "TABULATE";
- ▶ histograma este actualizată, fiind construită pentru mulțimea valorilor de selecție  $S_n$ .

## 2.5 Blocuri pentru obținerea de statistici (2.1)

- ▶ **TABLE/TABULATE** – reprezintă grafic histograma asociată unei mulțimi de selecție. Au forma generală:  
etHist TABLE A,B,C,D  
.....  
GENERATE A1,B1  
.....  
TABULATE etHist  
.....  
TERMINATE A2
  - ▶ etHist – numele histogramei, parametru obligatoriu
  - ▶ A – expresie care furnizează valori de selecție (generate cf. unei repartiții de probabilitate) asupra unei v.a.  $X$
  - ▶ B –  $a_1$ : marginea superioară a primului interval de frecvențe:  $l_1 = [a_0, a_1]$  (în notațiile din Curs 7)
  - ▶ C –  $l = a_i - a_{i-1}$ : lungimea unui interval de frecvențe
  - ▶ D –  $k$ : numărul intervalelor de frecvențe

## 2.5 Blocuri pentru obținerea de statistici (3)

- ▶ **QTABLE/QUEUE/DEPART** – reprezintă grafic histograma asociată timpilor de așteptare la un serviciu. Au forma generală:  
etHist QTABLE numeCoadă,B,C,D  
.....  
GENERATE A1,B1  
.....  
QUEUE numeCoadă  
.....  
DEPART numeCoadă  
.....  
TERMINATE A2
  - ▶ etHist – numele histogramei, element obligatoriu
  - ▶ numeCoadă – numele cozii de așteptare în care sunt introduse tranzacțiile pentru care se calculează timpul de așteptare pentru a primi un serviciu
  - ▶ B, C, D – parametri care definesc histograma; au aceleași semnificații ca pentru "TABLE"

## 2.6 Blocuri de control logic al tranzacțiilor (1)

- ▶ **TEST** – permite compararea unor valori și dirijarea tranzacțiilor în modelul de simulare. Are forma generală:  
TEST O A,B,etTransfer  
.....  
etTransfer BLOC parametri
  - ▶ O – este un operator relațional. Pentru un test cu succes trebuie să se verifice relația "A O B"; unde "O" poate lua valorile E = "=", G = ">", GE = ">=", L = "<", LE = "<=", NE = "≠"
  - ▶ A, B – sunt valorile comparate
  - ▶ etTransfer – reprezintă eticheta blocului la care este dirijată tranzacția în cazul în care testul nu are succes
- ▶ **Observație:** dacă testul are succes (adică, condiția este adevărată) tranzacția accesează următorul bloc din program.

## 2.6 Blocuri de control logic al tranzacțiilor (2)

- ▶ **TRANSFER** – permite dirijarea tranzacțiilor în modelul de simulare. Două modalități de utilizare sunt prezentate în cele ce urmează:  
TRANSFER ,etTransfer  
sau  
TRANSFER prob,,etTransfer  
unde  
etTransfer BLOC parametri
  - ▶ etTransfer – este eticheta blocului la care este dirijată tranzacția
  - ▶ prob – reprezintă probabilitatea cu care o tranzacție care accesează blocul "TRANSFER" este dirijată la blocul cu eticheta "etTransfer"; cu probabilitatea "1 - prob" tranzacția este trimisă la blocul următor din program

## 2.7 Blocuri de modificare a caracteristicilor tranzacțiilor și a valorilor unor entități de referință (1)

- ▶ **ASSIGN** – permite atribuirea/modificarea unei valori/valorii unui parametru asociat tranzacției care accesează blocul. Are forma generală:  
ASSIGN param[±],valoare
  - ▶ param – este identificatorul asociat parametruului/caracteristicii tranzacției; valoarea parametruului poate fi obținută folosind atributul P\$param (dacă "param" este șir de caractere) sau Pparam (dacă "param" este număr)
  - ▶ valoare – este valoarea atribuită sau cu care se incrementează sau decrementează parametrul tranzacției
- ▶ [±] – parantezele pătrate nu fac parte din sintaxa blocului; indică opționalitatea parametrilor "+" sau "-".
  - ▶ Dacă operatorii "+" sau "-" lipsesc atunci P\$param = valoare
  - ▶ Dacă blocul ASSIGN are sintaxa: "ASSIGN param+,valoare" atunci P\$param = P\$param + valoare
  - ▶ Dacă blocul ASSIGN are sintaxa: "ASSIGN param-,valoare" atunci P\$param = P\$param - valoare

## 2.7 Blocuri de modificare a caracteristicilor tranzacțiilor și a valorilor unor entități de referință (2)

- ▶ **SAVEVALUE** – permite atribuirea/modificarea unei valori/valorii unei variabile (globale) atunci când o tranzacție accesează blocul. Are forma generală:  
SAVEVALUE var[±],valoare
  - ▶ var – este identificatorul asociat variabilei; valoarea variabilei poate fi obținută folosind atributul X\$var (dacă "var" este șir de caractere) sau Xvar (dacă "var" este număr)
  - ▶ valoare – este valoarea atribuită sau cu care se incrementează sau decrementează variabila
- ▶ [±] – parantezele pătrate nu fac parte din sintaxa blocului; indică opționalitatea parametrilor "+" sau "-".
  - ▶ Dacă operatorii "+" sau "-" lipsesc atunci X\$var = valoare
  - ▶ Dacă blocul SAVEVALUE are sintaxa: "SAVEVALUE var+,valoare" atunci X\$var = X\$var + valoare
  - ▶ Dacă blocul SAVEVALUE are sintaxa: "SAVEVALUE var-,valoare" atunci X\$var = X\$var - valoare



## Obținerea unor caracteristici ale entităților GPSS (2)

- ▶ Variabile furnizând *informații despre blocuri*:
  - ▶ W\$etichetaBloc – numărul curent de tranzații aflate în blocul având eticheta "etichetaBloc"
  - ▶ N\$etichetaBloc – numărul total de tranzații care au intrat în blocul având eticheta "etichetaBloc"
- ▶ Variabile furnizând *informații despre facilitatea cu numele "resursă"*:
  - ▶ F\$resursă – indică starea curentă: 0 – liberă, 1 – ocupată
  - ▶ FC\$resursă – numărul de tranzații care au ocupat facilitatea
  - ▶ FR\$resursă – procentul de timp (din timpul total de simulare) cât a fost ocupată facilitatea (ia valori între 0 și 1000)
  - ▶ FT\$resursă – timpul mediu de ocupare de către o tranzație

## Obținerea unor caracteristici ale entităților GPSS (3)

- ▶ Variabile furnizând *informații despre punctul de servire cu mai multe stații sau entitatea de depozitare cu numele "resurse"*:
  - ▶ R\$resurse – numărul de stații/unități libere (care pot fi ocupate de tranzații)
  - ▶ S\$resurse – numărul de stații/unități ocupate
  - ▶ SA\$resurse – numărul mediu de stații/unități ocupate
  - ▶ SR\$resurse – procentul de utilizare
  - ▶ ST\$resurse – timpul mediu de utilizare a entităților
- ▶ Variabile furnizând *informații despre coada de așteptare cu numele "coadă"*:
  - ▶ Q\$coadă – numărul curent de tranzații din coada de așteptare
  - ▶ QA\$coadă – numărul mediu de tranzații din coadă
  - ▶ QM\$coadă – numărul maxim de tranzații aflate la un anumit moment al timpului de simulare în coadă
  - ▶ QC\$coadă – numărul total de tranzații care au intrat în coada de așteptare
  - ▶ QT\$coadă – timpul mediu de așteptare în coadă
  - ▶ QX\$coadă – timpul mediu de așteptare în coadă calculat pentru tranzațiile care au așteptat un timp strict pozitiv

## Folosirea repartițiilor de probabilitate în GPSS (1)

- ▶ Algoritmul de generare a numerelor (pseudo)aleatoare în GPSS se bazează pe *algoritmul multiplicativ – congruențial al lui Lehmer* cu o perioadă maximă de  $\lambda = 2^{31} - 2$ .
- ▶ *Atributul RNj* returnează o valoare întreagă în intervalul [0, 999].
- ▶ Comanda *RMULT* setează sămânța generatorului pentru generatorii "RNj, j = 1, ..., 7".
- ▶ În absența comenzii "RMULT" sămânța coincide cu numărul j al generatorului "RNj". De exemplu, RN2 pornește cu sămânța 2.

## Folosirea repartițiilor de probabilitate în GPSS (2)

- ▶ *Forma generală a unei funcții de generare* de valori de selecție asupra unei variabile aleatoare având o repartiție de probabilitate dată este (de obicei):

*numeRepartiție(nrGen, locație, scală, formă)*

unde

- ▶ *nrGen* – reprezintă numărul generatorului de numere aleatoare; trebuie să fie o valoare  $\geq 1$ .
- ▶ *locație, scală, formă* – sunt parametri ai repartiției de probabilitate

## Folosirea repartițiilor de probabilitate în GPSS (3)

▶ *Exemple* de funcții de generare de valori aleatoare

Repartiția de probabilitate	Funcția de generare
$X \sim U(a, b)$	UNIFORM(1, a, b)
$X \sim N(\mu, \sigma^2)$	NORMAL(1, $\mu$ , $\sigma$ )
$X \sim \text{Exp}(\alpha, \lambda)$	EXPONENTIAL(1, $\alpha$ , $1/\lambda$ )
$X \sim \text{Gamma}(\alpha, \lambda, \nu)$	GAMMA(1, $\alpha$ , $1/\lambda$ , $\nu$ )
$X \sim \text{Bin}(n, p)$	BINOMIAL(1, n, p)
$X \sim \text{Poisson}(\lambda)$	POISSON(1, $\lambda$ )

## Folosirea repartițiilor de probabilitate în GPSS (4)

▶ **FUNCTION** - este o comandă care definește o entitate funcție.  
Forma generală este:

nume FUNCTION A,B

$f_1, a_1/f_2, a_2/\dots/f_n, a_n$

- ▶  $f_1, f_2, \dots, f_n$  trebuie să verifice condiția  $f_1 < f_2 < \dots < f_n$
- ▶ nume - este o etichetă obligatorie prin care va fi accesată valoarea returnată de funcție
- ▶ A - este argumentul funcției (poate fi o expresie) ce va fi evaluat;
- ▶ B - este un parametru format dintr-o literă care indică tipul funcției (poate fi C - continuă sau D - discretă) și o valoare numerică reprezentând numărul  $n$  de perechi  $(f_i, a_i), i = 1, 2, \dots, n$  din definiția funcției.

▶ Pentru a obține valoarea returnată de funcție se folosește *atributul FN\$nume*.

## Folosirea repartițiilor de probabilitate în GPSS (5)

*Algoritm* care stă la baza comenzii "FUNCTION":

- ▶ Se evaluează expresia definită în argumentul funcției, notăm valoarea obținută cu  $A_0$
- ▶ Se determină indicele  $i$  minim pentru care  $A_0 \leq f_i$ .
- ▶ Avem următoarele cazuri:
  - ▶ Dacă  $f_n < A_0$  atunci  $FN\$nume = a_n$
  - ▶ Dacă  $A_0 < f_1$  atunci  $FN\$nume = a_1$
  - ▶ Dacă  $B = Cn$  și  $f_{i-1} < A_0 \leq f_i$  atunci valoarea funcției se obține prin interpolare cu formula:
$$FN\$nume = a_{i-1} + (a_i - a_{i-1}) \# (A_0 - f_{i-1}) / (f_i - f_{i-1})$$
  - ▶ Dacă  $B = Dn$  și  $f_{i-1} < A_0 \leq f_i$  atunci  $FN\$nume = a_i$

## Folosirea repartițiilor de probabilitate în GPSS (6)

*Folosirea entității funcție de tip continuu pentru simularea unei v.a. continue* (nu este recomandată, se recomandă folosirea funcțiilor de generare).

- ▶ Fie v.a. continuă  $X$  având funcția de repartiție  $F(x)$ . În acest caz,
  - ▶ argumentul funcției va fi generatorul de numere aleatoare RN1 (generează valori între 0 și 0.999999 când este folosit de comanda "FUNCTION")
  - ▶ Parametrii din sintaxa comenzii "FUNCTION":  
 $a_1 < a_2 < \dots < a_n$  și  $f_1 < f_2 < \dots < f_n$  sunt astfel încât

$$f_i = F(a_i) = P(X \leq a_i), \forall i = 1, 2, \dots, n$$

▶ *Exemplu:* aproximarea simulării v.a.  $X \sim \text{Exp}(1)$   
varC FUNCTION RN1,C10  
0.05,0.0513/0.15,0.1625/0.25,0.2877/0.35,0.4308/0.45,0.5978/  
0.55,0.7985/0.65,1.0498/0.75,1.3863/0.85,1.8971/0.95,2.9957



## Folosirea repartițiilor de probabilitate în GPSS (7)

- ▶ *Exemplu* de folosire a entității funcție de tip continuu pentru evaluarea unui argument și asocierea valorii corespunzătoare determinate prin interpolare

```
varC FUNCTION C1,C7
5,15/10,20/15,10/20,10/25,15/30,20/35,10
```

- ▶ Se evaluează argumentul funcției, C1 – timpul de simulare; de exemplu, dacă C1 = 22 atunci funcția va returna valoarea corespunzătoare lui A<sub>0</sub> = C1 = 22 prin interpolarea perechilor (20, 10) și (25, 15), și anume

$$FN\$varC = 10 + (15 - 10) \# (22 - 20) / (25 - 20) = 12$$

## Folosirea repartițiilor de probabilitate în GPSS (9)

- ▶ *Exemplu* de folosire a entității funcție de tip discret pentru evaluarea unui argument și asocierea valorii corespunzătoare

```
varD FUNCTION C1,D7
5,15/10,20/15,10/20,10/25,15/30,20/35,10
```

- ▶ Se evaluează argumentul funcției, C1 – timpul de simulare; de exemplu, dacă C1 = 22 atunci funcția va returna valoarea

$$FN\$varD = a_5 = 15$$

## Folosirea repartițiilor de probabilitate în GPSS (8)

*Folosirea entității funcție de tip discret pentru simularea unei v.a. discrete*

- ▶ Fie v.a. discretă X definită prin repartiția

$$X : \begin{pmatrix} a_1 & a_2 & \dots & a_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}, \sum_{i=1}^n p_i = 1, a_1 < a_2 < \dots < a_n.$$

- ▶ argumentul funcției va fi generatorul de numere aleatoare RN1
- ▶ Parametrii din sintaxa comenzii "FUNCTION":
  - {a<sub>1</sub>, a<sub>2</sub>, ..., a<sub>n</sub>} reprezintă valorile pe care le ia v.a. X
  - {f<sub>1</sub>, f<sub>2</sub>, ..., f<sub>n</sub>} reprezintă frecvențele cumulate, adică

$$f_i = p_1 + p_2 + \dots + p_i, i = \overline{1, n}$$

- ▶ *Exemplu*

```
varD FUNCTION RN1,D5
0.1,5/0.35,10/0.7,20/0.8,25/1,30
```

## Predefinirea unor expresii constante sau variabile (1)

*Predefinirea unor expresii constante*

- ▶ EQU - este o comandă care definește o entitate asociată unei expresii având o valoare constantă. Forma generală este:  
nume EQU X
  - ▶ X - este o expresie obligatorie având o valoare constantă
  - ▶ nume - este o etichetă obligatorie și reprezintă numele constantei ce va lua valoarea expresiei X.

*Exemplu care ilustrează folosirea constantei predefinite prin blocul "EQU"*

```
▶ timpServire EQU (150#72 + 36)
GENERATE 5
.....
SEIZE punctServire
ADVANCE timpServire
RELEASE punctServire
.....
TERMINATE 1
```



- ▶ **SAVEVALUE** – permite atribuirea/modificarea unei valori/valorii unei variabile (globale) atunci când o tranzație accesează blocul. Are forma generală:  
SAVEVALUE var[±],valoare
  - ▶ var – este identificatorul asociat variabilei; valoarea variabilei poate fi obținută folosind atributul X\$var (dacă "var" este șir de caractere) sau Xvar (dacă "var" este număr)
  - ▶ valoare – este valoarea atribuită sau cu care se incrementează sau decrementează variabila
- ▶ [±] – parantezele pătrate nu fac parte din sintaxa blocului; indică opționalitatea parametrilor "+" sau "-".
  - ▶ Dacă operatorii "+" sau "-" lipsesc atunci X\$var = valoare
  - ▶ Dacă blocul SAVEVALUE are sintaxa: "SAVEVALUE var+,valoare" atunci X\$var = X\$var + valoare
  - ▶ Dacă blocul SAVEVALUE are sintaxa: "SAVEVALUE var-,valoare" atunci X\$var = X\$var - valoare

- ▶ **Modelarea și simularea rezolvării unor proiecte diferite** (considerate în ordinea apariției sau ordonate în funcție de priorități) într-o firmă având mai multe departamente. Câteva modalități de abordare a proiectelor având ca scop rezolvarea acestora:
  - ▶ **rezolvarea secvențială a unui proiect:** proiectul va trece prin fiecare departament în mod secvențial în sensul că Departamentul 2 depinde de partea realizată de Departamentul 1, Departamentul 3 primește proiectul de la Departamentul 2, etc.
  - ▶ **rezolvarea în paralel a părților proiectului;** se presupune că pentru a se finaliza proiectul Departamentul 2 și Departamentul 3 trebuie să discute părțile realizate separat.

- ▶ **Modelarea și simularea dezvoltării unui produs** într-o fabrică având mai multe departamente
  - ▶ **construirea produsului în mod secvențial:** componenta construită în Departamentul 2 depinde de componenta contruită în Departamentul 1, etc.
  - ▶ **construirea produsului în paralel:** fiecare departament construiește o anumită componentă a produsului, în final "Departamentul asamblare" va realiza asamblarea componentelor și va construi produsul final.

- ▶ Presupunem că sucursala unei bănci deține 2 bancomate. Presupunem că suma maximă cu care este alimentat un bancomat este de 10000 de lei. Se realizează următoarele operațiuni:
  - ▶ la un interval repartizat exponențial de medie 20 de minute se extrag sume având valori repartizate uniform între 50 și 2000 de lei. Durata unei tranzații este de  $5 \pm 2$  minute.
  - ▶ La fiecare 2 ore un angajat al băncii verifică dacă bancomatul conține o sumă mai mică de 5000 de lei. În acest caz, soldul bancomatului va fi completat până la capacitatea maximă.
- ▶ Să se simuleze activitatea sistemului în primele 8 ore.

$$\begin{aligned} m_t &= E[X_t], \sigma_{st} = cov[X_s, X_t], s < t \text{ și} \\ m_t &= m = constant \text{ și } \sigma_{st} = \sigma(t-s). \end{aligned} \quad (3)$$

## 1.1 Generalități privind procesele stochastice (3)

- ▶ *Simularea proceselor stochastice* înseamnă producerea de puncte ale unei traiectorii finite
- ▶ *Simularea unui proces stochastic* constă în:
  - ▶ generarea unei valori  $X_0$  a procesului presupusă a se afla pe o traiectorie a sa la momentul  $t = 0$ ;
  - ▶ simularea unei valori  $X_1$  aflată pe aceeași traiectorie la momentul  $t = 1$  (care poate depinde de variabila  $X_0$ );
  - ▶ simularea unei valori  $X_2$  aflată pe aceeași traiectorie la momentul  $t = 2$  (care poate depinde de variabilele  $X_0$  și  $X_1$ ), etc.
- ▶ *Problema simulării unui proces stochastic* este mult mai complicată decât a variabilelor aleatoare, deoarece v.a.  $X_t$  generate la momentul de timp  $t$  pot să nu fie independente pentru diverse valori ale lui  $t$ .

## 1.2 Lanțuri și procese Markov (1)

- ▶ *Definiție:* Procesul  $\{X_t\}_{t \in T \subseteq \mathbb{R}}$  discret este un *proces Markov* dacă pentru orice  $t_1 < t_2 < \dots < t_n$  satisface proprietatea:

$$\begin{aligned} P(X_{t_n} = x_n \mid X_{t_{n-1}} = x_{n-1}, \dots, X_{t_1} = x_1) &= \\ &= P(X_{t_n} = x_n \mid X_{t_{n-1}} = x_{n-1}) \end{aligned} \tag{4}$$

adică procesul *nu are memorie*.

- ▶ *Definiție:* Probabilități

$$P(X_{t_n} = x_n \mid X_{t_{n-1}} = x_{n-1}) \tag{5}$$

se numesc *probabilități de tranziție sau probabilități de trecere*.

- ▶ Dacă  $T = \{0, 1, 2, \dots, n\}$  și  $S = \{1, 2, \dots, m\}$  atunci procesul Markov este un *lanț cu un număr finit de stări*.

## 1.2 Lanțuri și procese Markov (2)

- ▶ *Ipoteză:* Presupunem cunoscute probabilitățile inițiale:

$$p_i = P(X_t = i), \forall i \in S \tag{6}$$

- ▶ *Proprietate:* Dacă  $\{X_n\}_{n \in \mathbb{N}}$  este un lanț Markov are loc următoarea relație:

$$P(X_n = i_n, \dots, X_0 = i_0) = p_{i_0} \prod_{t=1}^n P(X_t = i_t \mid X_{t-1} = i_{t-1}) \tag{7}$$

- ▶ *Notăție:*

$$p_{t;i_{t-1}i_t} = P(X_t = i_t \mid X_{t-1} = i_{t-1}) \tag{8}$$

- ▶ *Definiție:* Un lanț Markov se numește *omogen* dacă  $p_{t;i_{t-1}i_t}$  nu depinde de  $t$  și notăm  $p_{t;i_{t-1}i_t} = p_{i_{t-1}i_t}$ . Altfel, se numește lanț *neomogen*.

## 1.2 Lanțuri și procese Markov (3)

- ▶ Pentru un lanț Markov omogen  $\{X_n\}_{n \in \mathbb{N}}$  considerăm matricea  $P = (p_{ij})_{i,j}$ , unde

$$p_{ij} = P(X_n = j \mid X_{n-1} = i), \forall n \in \mathbb{N}^* \tag{9}$$

numită *matrice de trecere*.

- ▶ Matricea de trecere  $P$  a unui lanț Markov omogen satisface relațiile:

$$p_{ij} \geq 0, \forall i, j \in S \text{ și } \sum_{j \in S} p_{ij} = 1, \forall i \in S \tag{10}$$

- ▶ Fiind dat un lanț Markov omogen, *vrem să determinăm probabilitățile*

$$P(X_{n+m} = j \mid X_m = i) \tag{11}$$

numite *probabilități de trecere în  $n$  pași*.

## 1.2 Lanțuri și procese Markov (4)

- Definim recursiv *șirul*  $p_{ij}^{(n)}$  prin

$$\begin{cases} p_{ij}^{(1)} = p_{ij} \\ p_{ij}^{(n+1)} = \sum_{k \in S} p_{ik}^{(n)} p_{kj}^{(1)}, n \in \mathbb{N}^* \end{cases} \quad (12)$$

- **Proprietate:** Pentru orice  $n \in \mathbb{N}$  avem relația

$$p_{ij}^{(n)} = P(X_{n+m} = j \mid X_m = i), m \in \mathbb{N} \quad (13)$$

- Dacă într-un lanț Markov omogen se cunosc **probabilitățile inițiale** și **probabilitățile de tranziție** atunci probabilitatea ca la momentul  $n \in \mathbb{N}$  sistemul să se afle în starea  $i, i \in S$ , pe care o notăm  $p_i(n) = P(X_n = i)$  este

$$p_i(n) = \sum_{j \in S} p_j(n-1)p_{ji}. \quad (14)$$

### 1.3 Exemplu: modelarea unui sistem de așteptare folosind lanțuri Markov (2)

- O formulă recursivă pentru lantul  $Y_n$

$$Y_{n+1} = \begin{cases} Y_n - 1 + X_n, & \text{dacă } 1 \leq Y_n \leq m, 0 \leq X_n \leq m + 1 - Y_n \\ X_n, & \text{dacă } Y_n = 0, 0 \leq X_n \leq m - 1 \\ m, & \text{în rest} \end{cases}$$

- Notăm cu  $\overline{p}_m = p_m + p_{m-1} + \dots + p_0$ . Probabilitățile de tranziție pot fi calculate cu formulele:

$$p_{0j} = P(Y_{n+1} = j \mid Y_n = 0) = \begin{cases} P(X_n = j) = p_j & \text{dac}\acute{a} \ 0 \leq j \leq m-1 \\ P(X_n \geq m) = 1 - \bar{p}_m & \text{dac}\acute{a} \ j = m \end{cases}$$

$$p_{ij} = P(Y_{n+1} = j \mid Y_n = i) = \begin{cases} P(X_n = j + 1 - i) = p_{j-i+1} & \text{dac}\breve{a} \ i - 1 \leq j \leq m - 1 \\ P(X_n \geq m + 1 - i) = 1 - \bar{p}_{m+1-i} & \text{dac}\breve{a} \ j = m \\ 0, & \text{altfel} \end{cases}$$

### 1.3 Exemplu: modelarea unui sistem de așteptare folosind lanțuri Markov (1)



- *Ipoteze ale modelului:*

- ▶ Sistemul conține o stație de servire care poate servi clienții la momentele  $0, 1, 2, \dots$ .
- ▶ Definim v.a.  $X_n$  – numărul de clienți care sosesc în intervalul  $(n, n+1)$ . Presupunem că v.a.  $X_n$  sunt i.i.d.:

$$X_n: \left( \begin{matrix} k \\ p_k \end{matrix} \right)_{k=0}^{\infty}, \sum_{k=0}^{\infty} p_k = 1. \quad (15)$$

- ▶ Se consideră că există un loc de așteptare pentru cel mult  $m$  clienți (inclusiv clientul care este servit); clienții care găsesc  $m$  clienți în sistem pleacă fără a fi serviți.
- ▶ Fie  $Y_n$  – numărul de clienți din sistem la momentul  $n$  (incluzând și clientul care este servit)
- ▶ Rezultă că  $\{Y_n\}_{n \in \mathbb{N}}$  este un lanț Markov cu stările  $0, 1, 2, \dots, m$ , deoarece  $Y_{n+1}$  depinde doar de  $Y_n$ , iar  $Y_{n+1}$  și  $X_n$  sunt independente.

## Bibliografie I

-  I. Văduva (2004), *Modele de simulare: note de curs*, Editura Universității din București, București
-  A. L. Pletea, L. Popa (1999), *Teoria probabilităților*, Disponibil la: <http://math.etti.tuiasi.ro/lpopa/cursTP.pdf>, Ultima accesare: ianuarie 2015